

Session 3. Transformations de variables et interactions entre variables explicatives

À la fin de cette session, vous devez être capable de : repérer les deux façons dont le modèle linéaire de base peut être faux (effet non linéaire, effet non additif) ; corriger la non-linéarité avec une transformation de variable et lire correctement son effet ; corriger la non-additivité avec un terme d'interaction (interaction term), pour n'importe quelle combinaison de variables quantitatives/muettes/multi-catégorielles ; et choisir le bon test de significativité pour un terme transformé ou une interaction.

Plan

1. Les deux hypothèses cachées du modèle de base, et comment elles peuvent être fausses
2. Corriger la non-linéarité : transformer une variable explicative
3. Lire l'effet d'une variable transformée
4. La transformation logarithmique : lire l'effet en pourcentage
5. Corriger la non-additivité : qu'est-ce qu'un terme d'interaction
6. Interaction entre une variable quantitative et une variable muette
7. Interaction avec une variable à plusieurs catégories, ou entre deux variables quantitatives/deux variables muettes
8. Tester si une transformation ou une interaction compte vraiment
9. Erreurs courantes et pièges d'examen
10. À savoir absolument

1. Les deux hypothèses cachées du modèle de base, et comment elles peuvent être fausses

L'équation de régression multiple ordinaire $Y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon$ contient silencieusement deux hypothèses sur la façon dont le monde fonctionne. Cette session sert entièrement à assouplir ces deux hypothèses.

- **Hypothèse 1 — l'effet de chaque x_j est linéaire (linearity).** Cela signifie, par construction :
 - Une augmentation d'une unité de x_j a exactement le même effet sur $E(Y)$, quelle que soit la valeur de départ de x_j .
 - Une augmentation de taille c de x_j a un effet exactement c fois plus grand que celui d'une augmentation d'une unité.
- **Hypothèse 2 — l'effet de chaque variable est additif (additivity).** Cela signifie que l'effet d'une variable sur $E(Y)$ reste le même quels que soient les niveaux fixés des autres variables explicatives.

Les deux hypothèses peuvent être irréalistes. Exemple fil rouge de toute la session : Y = le chiffre d'affaires d'un produit, x_1 = l'investissement publicitaire, $x_2 = 1$ si le produit vient d'être lancé sur le marché, 0 sinon.

- Il est tout à fait plausible qu'une augmentation de la publicité de 100 à 101 ait un effet plus petit qu'une augmentation de 1 à 2 — cela violerait l'Hypothèse 1 (non-linéarité, non-linearity).
- Il est tout à fait plausible que l'effet de la publicité soit différent pour un produit tout juste lancé que pour un produit déjà installé — cela violerait l'Hypothèse 2 (non-additivité, non-additivity).

Petit exemple chiffré pour bien fixer les idées avant de continuer : imaginez que chaque euro dépensé en publicité rapporte de moins en moins de chiffre d'affaires supplémentaire à mesure que le budget grandit (10 000€ de plus quand on part de 1 000€ ne rapporte pas autant que 10 000€ de plus quand on part de 10€) — c'est de la non-linéarité. Si, en plus, ce même euro dépensé rapporte plus pour un produit nouveau que pour un produit ancien — c'est de la non-additivité. Les deux peuvent arriver en même temps, mais ce sont deux problèmes différents.

Deux outils séparés corrigent ces deux problèmes séparés, et il est important de ne pas les confondre :

- Non-linéarité → corrigée avec une **transformation de variable** (variable transformation).
- Non-additivité → corrigée avec une **interaction** (interaction) entre variables.

2. Corriger la non-linéarité : transformer une variable explicative

Transformation de variable (variable transformation) : pour une variable explicative quantitative x , on introduit dans le modèle — à la place de x , ou en plus de x — une fonction de x telle que $\log(x)$, x^2 , x^3 , etc. L'effet de x sur $E(Y)$ n'est alors plus obligatoirement linéaire.

Avec $\log(x)$ par exemple : l'effet d'une augmentation d'une unité de x sur $E(Y)$ devient de plus en plus petit à mesure que x grandit, et l'effet d'une augmentation de c unités de x n'est plus simplement c fois l'effet d'une augmentation d'une unité à partir du même point de départ.

Trois règles pratiques pour bien construire ce type de modèle, directement issues des slides :

- **Le logarithme exige des valeurs strictement positives.** La transformation logarithmique ne peut être appliquée qu'à une variable qui ne prend que des valeurs strictement positives (jamais zéro ni négative).
- **On garde toujours les puissances inférieures.** Si on introduit un terme de puissance comme x^2 , la convention habituelle est de garder aussi le terme d'ordre inférieur x dans le modèle (donc x et x^2 ensemble, jamais x^2 seul).
- **Ce qui décide s'il faut transformer ou non :**
 - le contexte concret (est-ce que ça a du sens que l'effet accélère ou ralentisse ?), et
 - les données de l'échantillon elles-mêmes, vérifiées formellement avec des tests de significativité sur les termes transformés, et avec le R^2 ajusté quand on compare des spécifications de modèle qui ne sont pas emboîtées (nested).

3. Lire l'effet d'une variable transformée

Une fois que x est transformée, son effet sur Y n'est plus un simple coefficient fixe — il faut le réexprimer soit comme un taux de variation instantané (local) à un point précis, soit comme le changement réel (fini) entre deux valeurs précises de x . Ce sont deux nombres différents qui répondent à deux questions différentes.

Mise en situation : équation estimée $\hat{y} = 2 + 6x_1 - x_1^2 + 4x_2$ (un terme quadratique sur x_1).

3.1 Le taux de variation instantané (local) — la dérivée (derivative)

$$d(\hat{y})/dx_1 = \lim (\Delta \hat{y} / \Delta x_1) \text{ quand } \Delta x_1 \rightarrow 0 = 6 - 2x_1$$

où :

- $6 - 2x_1$ est la dérivée de $\hat{y}$ par rapport à x_1 , x_2 étant maintenu fixe
- elle n'est **pas constante** : elle dépend de la valeur de x_1 à laquelle on l'évalue

Ce que ça calcule concrètement, étape par étape :

- Ça donne l'effet marginal estimé de x_1 à un point de départ précis de x_1 — pas pour un déplacement complet d'une unité.
- Comme la pente $6 - 2x_1$ diminue quand x_1 augmente, elle peut même changer de signe : positive pour un petit x_1 , négative pour un grand x_1 .
- Il ne faut jamais la lire comme "le changement de $\hat{y}$ pour une unité de x_1 en plus" — c'est une quantité différente, finie, qu'on voit juste après.

3.2 Le changement réel sur un déplacement concret — la différence finie (finite difference)

Pour obtenir le vrai changement de $\hat{y}$ entre deux valeurs réelles de x_1 (par exemple de 1 à 2, x_2 fixé), on ne peut pas simplement utiliser la dérivée — il faut calculer la différence finie entre les deux valeurs ajustées (ce qui revient à intégrer la dérivée sur cet intervalle). D'après les slides, pour cet exemple :

- x_1 passe de 1 à 2 → la moyenne estimée de Y **augmente** de 3.
- x_1 passe de 2 à 3 → la moyenne estimée de Y **augmente** de 1.
- x_1 passe de 4 à 5 → la moyenne estimée de Y **diminue** de 3.

Remarquez que le même "+1" sur x_1 produit un effet différent selon d'où l'on part : c'est exactement ce que "non linéaire" veut dire.

Attention : "entraîne une augmentation/diminution" est une affirmation statistique (associative) issue du modèle ajusté, jamais une affirmation causale.

4. La transformation logarithmique : lire l'effet en pourcentage

Pour un x transformé en logarithme, il existe un raccourci pratique : lire l'effet comme un changement en pourcentage approximatif, valable uniquement pour de petits déplacements en pourcentage de x .

$$\hat{y}_{\text{incr}} - \hat{y}_{\text{sans incr}} = b_1[\log(x + 0.01x) - \log(x)] = b_1 \cdot \log(1.01) \approx 0.01 \cdot b_1$$

où :

- le modèle est $\hat{y} = b_0 + b_1 \log(x)$
- l'augmentation considérée est une hausse de 1% de x
- b_1 est le coefficient estimé sur $\log(x)$

Ce que ça calcule concrètement, étape par étape :

- On part de la valeur ajustée du modèle log, puis on augmente x d'exactly 1%.
- Le changement de $\hat{y}$ vaut $b_1 \cdot \log(1.01)$, ce qui est approximativement égal à $0.01 \cdot b_1$ (cette approximation n'est valable que pour un petit déplacement en pourcentage — elle devient fautive pour un gros déplacement).
- Lecture : une hausse de 1% de x est associée à un changement estimé de $\text{mean}(Y)$ d'environ $0.01 \cdot b_1$.
- De façon équivalente : b_1 lui-même est le changement estimé de $\text{mean}(Y)$ pour une augmentation d'une unité de $\log(x)$ — une deuxième façon, exacte cette fois, de lire le même coefficient.

Exemple chiffré (publicité/chiffre d'affaires) : $\hat{y} = 2.4 + 0.3 \cdot \log(x_1) - 0.9x_2$, x_2 étant fixé :

- investissement 1 → 2 : $0.3 \cdot (\log 2 - \log 1) = 0.208$
- investissement 10 → 11 : $0.3 \cdot (\log 11 - \log 10) = 0.029$
- investissement 100 → 101 : $0.3 \cdot (\log 101 - \log 100) = 0.003$

Le même bond de +1 en valeur absolue de x_1 rapporte de moins en moins de chiffre d'affaires à mesure que le niveau de départ augmente. Avec le raccourci du 1%, à n'importe quel niveau, une hausse de 1% de l'investissement augmente le chiffre d'affaires moyen d'environ $b_1 \cdot 0.01 = 0.3 \cdot 0.01 = 0.003$.

Attention : les lectures " $b_1 \cdot 0.01$ par 1%" et "effet de $b_1\%$ " d'un x transformé en logarithme sont une approximation du premier ordre — valable seulement pour de petits changements en pourcentage de x , pas exacte pour un grand saut.

Deux remarques finales sur les transformations, directement issues des slides :

- Transformer une variable explicative peut, dans certains cas, corriger aussi une violation des hypothèses du modèle (lien avec la Session 4).

- Les transformations ne se limitent pas aux variables explicatives — la variable dépendante Y peut elle aussi être transformée ($\log(Y)$ et modèles log-log/log-lin, vus en Session 4).

5. Corriger la non-additivité : qu'est-ce qu'un terme d'interaction

Terme d'interaction (interaction term) : le produit algébrique $x_1 \cdot x_2$ de deux variables explicatives, ajouté à un modèle qui contient déjà x_1 et x_2 comme effets principaux (main effects), pour que l'effet d'une variable puisse dépendre du niveau de l'autre.

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{\text{int}} x_1 x_2 + \varepsilon$$

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + b_{\text{int}} x_1 x_2$$

où :

- β_1, β_2 sont les deux coefficients des effets principaux (comme d'habitude)
- β_{int} est le coefficient du terme d'interaction (produit) $x_1 x_2$

Ce que ça calcule concrètement, étape par étape :

- Sans le terme produit, l'effet de x_1 sur $E(Y)$ ne peut absolument pas changer, quelle que soit la valeur fixée de x_2 (c'est exactement l'hypothèse d'additivité de la Section 1).
- Ajouter $x_1 x_2$ casse cette contrainte : l'effet de x_1 peut désormais varier d'une quantité liée au niveau de x_2 (et symétriquement, l'effet de x_2 varie avec le niveau de x_1).
- β_{int} mesure littéralement la taille de cette variation par unité de l'autre variable.

Une interaction peut être construite entre n'importe quelle combinaison de types de variables : deux variables quantitatives, une variable quantitative et une variable muette/qualitative, ou deux variables muettes/qualitatives. Le cas le plus courant en pratique — et celui à maîtriser en premier — est quantitative $\times$ muette, vu juste après.

6. Interaction entre une variable quantitative et une variable muette

Prenons le modèle estimé $\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + b_{\text{int}} x_1 x_2$, avec x_1 quantitative et x_2 une variable muette (dummy variable) 0/1. En remplaçant chaque valeur de x_2 , cette unique équation se transforme en deux équations distinctes :

$$x_2 = 0 : \hat{y} = b_0 + b_1 x_1$$

$$x_2 = 1 : \hat{y} = b_0 + b_1 x_1 + b_2 + b_{\text{int}} x_1 = (b_0 + b_2) + (b_1 + b_{\text{int}}) x_1$$

où :

- $(b_0 + b_2)$ est l'ordonnée à l'origine (intercept) de la droite $x_2 = 1$
- $(b_1 + b_{\text{int}})$ est la pente (slope) sur x_1 pour la droite $x_2 = 1$

Ce que ça calcule concrètement, étape par étape :

- On pose $x_2 = 0$ dans l'équation complète : le terme d'interaction disparaît totalement (il est multiplié par 0), il ne reste qu'une droite simple en x_1 .
- On pose $x_2 = 1$ dans l'équation complète : b_2 s'ajoute à l'ordonnée à l'origine, et b_{int} s'ajoute à la pente sur x_1 — parce que $b_{\text{int}} x_1 x_2$ devient $b_{\text{int}} x_1$.
- Résultat : deux droites avec **une ordonnée à l'origine ET une pente différentes** — pas juste décalées vers le haut/le bas, mais inclinées différemment.
- C'est exactement à quoi ressemble sur un graphique "l'effet de x_1 dépend du niveau de x_2 ". Une simple variable muette sans interaction ne peut que décaler une droite vers le haut ou vers le bas (deux droites

parallèles) ; c'est l'interaction qui permet à la pente elle-même de changer.

Pour bien visualiser : imaginez le prix d'un bien immobilier (Y) selon sa surface (x_1) et selon qu'il soit neuf ou ancien ($x_2 = 1$ si neuf). Sans interaction : le prix augmente avec la surface au même rythme, que le bien soit neuf ou ancien — seule la hauteur de départ change. Avec interaction : chaque mètre carré supplémentaire peut valoir plus cher dans le neuf que dans l'ancien — les deux droites ne sont plus parallèles, elles s'écartent (ou se rapprochent) à mesure que la surface augmente.

Attention : si b_{int} se révèle non significatif, le modèle revient en pratique à deux droites parallèles (même pente, ordonnées à l'origine différentes) — toujours vérifier la significativité du terme d'interaction lui-même avant de conclure que l'effet diffère vraiment selon les groupes.

7. Interaction avec une variable à plusieurs catégories, ou entre deux variables quantitatives/deux variables muettes

7.1 Quantitative $\times$ variable à plusieurs catégories

Quand la deuxième variable x_2 est qualitative avec k catégories, le modèle contient déjà $k-1$ variables muettes (disons x_B et x_C pour $k = 3$, par rapport à la catégorie de référence (reference category) A). L'interaction nécessite maintenant **un terme produit par variable muette non-référence** : x_1x_B et x_1x_C .

$$\hat{y} = b_0 + b_1x_1 + b_Bx_B + b_Cx_C + b_{intB}x_1x_B + b_{intC}x_1x_C$$

Ce que ça calcule concrètement, étape par étape — ça produit trois droites distinctes, une par catégorie :

- catégorie A (référence) : $\hat{y} = b_0 + b_1x_1$
- catégorie B : $\hat{y} = (b_0 + b_B) + (b_1 + b_{intB})x_1$
- catégorie C : $\hat{y} = (b_0 + b_C) + (b_1 + b_{intC})x_1$
- Chaque catégorie obtient à la fois sa propre ordonnée à l'origine et sa propre pente sur x_1 .

7.2 Deux variables quantitatives

Sans autre variable, l'équation est $\hat{y} = b_0 + b_1x_1 + b_2x_2 + b_{int}x_1x_2$, qu'on peut réécrire ainsi :

$$\hat{y} = b_0 + x_1(b_1 + b_{int}x_2) + b_2x_2$$

Ce que ça calcule concrètement, étape par étape :

- La pente effective sur x_1 est maintenant le terme entier $(b_1 + b_{int}x_2)$, et non plus juste b_1 seul.
- Cette pente change continûment selon la valeur à laquelle x_2 est fixée — il n'y a plus une seule pente pour x_1 .
- Par symétrie, le même raisonnement s'applique à la pente effective sur x_2 , qui dépend de x_1 .

7.3 Deux variables muettes

L'algèbre a exactement la même forme que dans le cas de deux variables quantitatives :

- $x_2 = 1$: l'effet de x_1 est $b_1 + b_{int}$.
- $x_2 = 0$: l'effet de x_1 est simplement b_1 .

À savoir :

- Interaction quantitative $\times$ muette $\rightarrow$ pente différente sur x_1 selon le groupe (droites non parallèles).
- Interaction quantitative $\times$ k catégories $\rightarrow$ k droites différentes, une pente et une ordonnée à l'origine par catégorie.

- Interaction quantitative $\times$ quantitative $\rightarrow$ la pente effective sur chaque variable est elle-même une fonction linéaire de la valeur de l'autre variable.

8. Tester si une transformation ou une interaction compte vraiment

La question de savoir si une interaction est statistiquement significative — c'est-à-dire s'il existe une vraie preuve que l'effet d'une variable dépend du niveau d'une autre — se teste différemment selon le nombre de termes impliqués :

- **Un seul terme d'interaction** $\rightarrow$ un simple test t (t-test) sur b_{int} ($H_0 : \beta_{\text{int}} = 0$).
- **Plusieurs termes d'interaction en même temps** (par exemple x_1x_B et x_1x_C ensemble, pour une interaction à 3 catégories) $\rightarrow$ un test F partiel (partial F-test) pour tester leur significativité conjointe — exactement la même logique de test F partiel que dans la Session 2, appliquée cette fois à un groupe de termes d'interaction plutôt qu'à un groupe de variables muettes d'effet principal.

Une situation liée : une variable peut apparaître dans le modèle sous **plus d'une forme à la fois** — par exemple comme effet principal, à l'intérieur d'une interaction, et sous une forme transformée (quadratique).

- Pour juger si cette variable compte globalement, **tous ses termes doivent être testés conjointement**, avec un seul test F partiel.
- Un test t non significatif sur un seul de ces termes (disons, l'effet principal tout seul) ne dit rien sur la pertinence globale de la variable une fois ses autres formes prises en compte ensemble.

Des interactions entre plus de deux variables sont aussi possibles, construites de la même façon, en ajoutant les termes produits d'ordre supérieur correspondants au modèle.

9. Erreurs courantes et pièges d'examen

- Lire le coefficient d'une variable transformée comme s'il s'agissait d'un effet marginal constant (comme pour un terme linéaire non transformé) — avec $\log(x)$ ou x^2 , l'effet doit être évalué à une valeur précise de x , ou présenté comme une différence finie entre deux valeurs précises.
- Appliquer $\log(x)$ à une variable qui peut être nulle ou négative — le logarithme exige des valeurs strictement positives.
- Ajouter un terme au carré x^2 sans garder le terme linéaire x dans le modèle.
- Oublier que le raccourci de "l'effet en pourcentage" basé sur le $\log$ ($0.01 \cdot b_1$ pour +1%) n'est qu'une approximation valable pour de petits changements en pourcentage.
- Interpréter un modèle variable muette + interaction comme s'il produisait toujours des droites parallèles entre les groupes — tout l'intérêt de l'interaction est justement que ce n'est plus nécessairement le cas.
- Tester plusieurs termes d'interaction/transformation appartenant à la même variable un par un avec des tests t séparés, au lieu de les tester conjointement avec un test F partiel.
- Confondre "l'effet de x dépend de x lui-même" (un problème de non-linéarité, corrigé en transformant x) avec "l'effet de x dépend d'une autre variable" (un problème de non-additivité, corrigé par une interaction) — ce sont deux problèmes différents, avec deux corrections différentes, qui ne s'échangent pas.

10. À savoir absolument

À savoir :

- Deux façons dont le modèle linéaire-additif de base peut échouer : la non-linéarité (corrigée en transformant x) et la non-additivité (corrigée en ajoutant une interaction).

- Après une transformation, présenter l'effet soit comme une dérivée locale en un point précis, soit comme une différence finie entre deux valeurs de x — jamais comme un seul coefficient fixe.
- $\log(x)$: une hausse d'environ 1% de $x \rightarrow \text{mean}(Y)$ change d'environ $0.01 \cdot b_1$; de façon équivalente, b_1 est l'effet d'une augmentation d'une unité de $\log(x)$.
- Terme d'interaction = produit de deux variables ; son coefficient mesure comment l'effet d'une variable change avec le niveau de l'autre.
- Interaction quantitative $\times$ muette $\rightarrow$ ordonnée à l'origine ET pente différentes par groupe.
- Un seul terme d'interaction $\rightarrow$ test t ; plusieurs termes d'interaction ensemble, ou une variable apparaissant sous plusieurs formes $\rightarrow$ test F partiel.

Points de vigilance

Attention : "entraîne une augmentation/diminution" en lisant une différence finie est une affirmation statistique (associative) issue du modèle ajusté, jamais une affirmation causale.

Attention : les lectures " $b_1 \cdot 0.01$ par 1%" et "effet de $b_1\%$ " d'un x transformé en logarithme sont une approximation du premier ordre — valable seulement pour de petits changements en pourcentage de x , pas exacte pour un grand saut.

Attention : un modèle avec x_1 , x_2 et leur interaction, mais un b_{int} non significatif, se réduit en pratique à deux droites parallèles (même pente, ordonnées à l'origine différentes) — toujours vérifier la significativité du terme d'interaction avant de conclure que l'effet diffère vraiment selon les groupes.