

Session 6. Le modèle de régression logistique pour variable binaire (Logit Model)

À la fin de cette session, vous devez être capable de : définir la probabilité et la cote (odds) d'un événement et passer de l'une à l'autre ; écrire l'équation du modèle logit (logit model) pour une variable dépendante binaire Y ; interpréter le coefficient estimé b_j selon que x_j est quantitative ou dichotomique, via le rapport de cotes (odds ratio) ; et tester la significativité d'un coefficient individuel.

Plan

1. Rappel, probabilité et cote (odds)
2. Le modèle de régression logistique, variable dépendante binaire
3. Équation théorique du modèle
4. Estimation des paramètres
5. Interpréter b_j , cas d'une variable quantitative
6. Interpréter b_j , cas d'une variable dichotomique
7. Exemple travaillé
8. Test sur un coefficient individuel
9. Erreurs fréquentes et pièges à l'examen
10. À retenir absolument

1. Rappel, probabilité et cote (odds)

- Soit E un événement, de probabilité $P(E) = p$. La cote (odds) de E se définit ainsi :

$$\text{ODDS} = p / (1 - p)$$

où :

- p est la probabilité que l'événement E se produise.
- $1 - p$ est la probabilité qu'il ne se produise pas.

Ce que cette formule dit, étape par étape :

- La cote est le ratio entre la probabilité que l'événement se produise et la probabilité qu'il ne se produise pas.
- Elle est très utilisée dans les paris sportifs (sports betting).
- Il existe une correspondance biunivoque et croissante entre probabilité et cote :

$$\text{ODDS} = p / (1 - p) \Leftrightarrow p = \text{ODDS} / (1 + \text{ODDS})$$

- p varie entre 0 et 1, tandis que ODDS varie entre 0 et $+\infty$.

Exemples numériques (slides) : $p = 0.5 \Leftrightarrow \text{ODDS} = 1$ • $p = 0.2 \Leftrightarrow \text{ODDS} = 0.25$ • $p = 0.75 \Leftrightarrow \text{ODDS} = 3$.

- Règle générale à retenir directement :
- $\text{ODDS} > 1 \Leftrightarrow p > 0.5$
- $\text{ODDS} < 1 \Leftrightarrow p < 0.5$
- $\text{ODDS} = 1 \Leftrightarrow p = 0.5$
- Le modèle logit utilise en réalité le **logarithme de la cote** (log-odds), $\log(\text{ODDS})$: une fonction strictement croissante de p .
- Quand $p \rightarrow 0$, $\log(\text{ODDS}) \rightarrow -\infty$.

- Quand $p \rightarrow 1$, $\log(\text{ODDS}) \rightarrow +\infty$.

2. Le modèle de régression logistique, variable dépendante binaire

Modèle de régression logistique (logistic regression model) : modèle dans lequel la variable dépendante Y est une variable dichotomique (dichotomous), aussi appelée variable de Bernoulli ou variable dummy. Y prend la valeur 1 avec probabilité p et la valeur 0 avec probabilité $1 - p$; p représente aussi la moyenne (l'espérance $E(Y)$) de la variable Y .

- 1 et 0 ne sont que des codes numériques représentant un événement et sa négation, respectivement.

Exemples (slides) : $Y = 1$ peut indiquer la faillite d'une entreprise, l'achat d'un certain produit par un consommateur, le défaut d'un débiteur, etc.

3. Équation théorique du modèle

$$p = e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p} / (1 + e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p})$$

ou, de façon équivalente (c'est cette seconde formulation qui est utilisée en pratique) :

$$\log(p / (1 - p)) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

Ce que cette équation dit, étape par étape :

- Le modèle exprime la moyenne de la variable dépendante, $p = E(Y)$, comme une fonction (non linéaire) des variables explicatives $x_1, \dots, x_p$.
- La seconde formulation exprime le **log-odds** (le logarithme de la cote) de l'événement $Y = 1$ comme une fonction **linéaire** des variables explicatives — c'est ce qui permet d'utiliser des coefficients β comme en régression linéaire.

4. Estimation des paramètres

- Les estimations des paramètres inconnus $\beta_0, \beta_1, \dots, \beta_p$ sont obtenues par la méthode du **maximum de vraisemblance (Maximum Likelihood Estimation)**, dans laquelle nous n'entrerons pas — le logiciel R les fournit directement. On note les estimations $b_0, b_1, \dots, b_p$.
- L'équation estimée du modèle est donc :

$$\log(\hat{p} / (1 - \hat{p})) = b_0 + b_1 x_1 + \dots + b_p x_p$$

où $\hat{p}$ (p -hat) est la probabilité estimée de l'événement $Y = 1$.

5. Interpréter b_j , cas d'une variable quantitative

- On compare l'équation estimée avec x_j augmentée d'une unité à l'équation estimée avec x_j inchangée (les autres variables maintenues constantes).
- En soustrayant les deux équations, tous les termes s'annulent sauf b_j :

$$\log(\hat{p}_{incr} / (1 - \hat{p}_{incr})) - \log(\hat{p} / (1 - \hat{p})) = b_j$$

- En prenant l'exponentielle des deux côtés, la différence de logarithmes devient un ratio :

$$(\hat{p}_{incr} / (1 - \hat{p}_{incr})) \div (\hat{p} / (1 - \hat{p})) = e^{b_j}$$

Rapport de cotes estimé (odds ratio), e^{b_j} : le ratio entre la cote de l'événement $Y = 1$ correspondant à x_j augmentée d'une unité, et la cote du même événement correspondant à x_j non augmentée, toutes les autres variables maintenues constantes.

Ce que cela signifie concrètement, étape par étape :

- On estime que la cote de l'événement ($Y = 1$) correspondant à une augmentation d'une unité de x_j est e^{b_j} fois la cote correspondant à x_j non augmentée, les autres variables étant maintenues constantes.
- Si $b_j > 0$ (donc $e^{b_j} > 1$) : la cote estimée augmente, donc la probabilité estimée de l'événement augmente aussi.
- Si $b_j < 0$ (donc $e^{b_j} < 1$) : la cote estimée diminue, donc la probabilité estimée diminue.

Attention : e^{b_j} donne un facteur multiplicatif sur la **cote**, pas directement le changement de la **probabilité**. On sait dans quel sens la probabilité bouge (même sens que la cote), mais en général on ne peut pas dire précisément de combien elle augmente ou diminue à partir de b_j seul.

6. Interpréter b_j , cas d'une variable dichotomique

- Même raisonnement, mais on compare $x_j = 1$ à $x_j = 0$ (au lieu de "+1 unité"), les autres variables étant maintenues constantes.
- On obtient exactement la même relation :

$$(\hat{p}_{x_j=1} / (1 - \hat{p}_{x_j=1})) \div (\hat{p}_{x_j=0} / (1 - \hat{p}_{x_j=0})) = e^{b_j}$$

Rapport de cotes (odds ratio), cas dichotomique : e^{b_j} est le ratio entre la cote de l'événement $Y = 1$ quand $x_j = 1$, et la cote du même événement quand $x_j = 0$, les autres variables étant maintenues constantes.

- Si $b_j > 0$ ($e^{b_j} > 1$) : la cote estimée est plus élevée (et donc la probabilité estimée de l'événement est plus grande) pour les unités où $x_j = 1$, par rapport à celles où $x_j = 0$.
- Si $b_j < 0$ ($e^{b_j} < 1$) : la cote estimée est plus faible quand $x_j = 1$.

7. Exemple travaillé

Exemple (slides) : $Y = 1$ si le consommateur connaît un certain produit, $Y = 0$ sinon. x_1 = âge du consommateur (quantitative). $x_2 = 1$ si le consommateur est une femme, $x_2 = 0$ si c'est un homme (dichotomique).

Équation estimée : $\log(\hat{p}/(1-\hat{p})) = 1.5 + 0.2x_1 - 0.8x_2$

- Interprétation de l'effet de x_1 (âge) : $b_1 = 0.2$, donc $e^{0.2} = 1.2214$.
- x_2 étant fixé, la cote estimée de l'événement "le consommateur connaît le produit" augmente de 22.14% pour chaque année d'âge supplémentaire (elle est multipliée par 1.2214).

- La probabilité de l'événement augmente donc aussi avec l'âge (x_2 fixé), mais on ne peut pas dire précisément de combien.
- Interprétation de l'effet de x_2 (femme/homme) : $b_2 = -0.8$, donc $e^{-0.8} = 0.4493$.
- x_1 étant fixé, la cote estimée de l'événement pour les femmes vaut 44.93% de la cote estimée pour les hommes.
- La probabilité de l'événement est donc plus faible pour les femmes que pour les hommes (âge fixé), mais là encore on ne peut pas dire précisément de combien elle diminue.

8. Test sur un coefficient individuel

- Une estimation b_j différente de 0 ne garantit pas que la variable x_j a un effet réel dans la population : il faut un test d'hypothèse sur β_j .

Test sur un coefficient individuel : $H_0 : \beta_j = 0$ contre $H_1 : \beta_j \neq 0$. Rejeter H_0 signifie conclure (avec une marge d'erreur donnée par le niveau de signification du test) que x_j a un effet dans la population, c'est-à-dire que la variable x_j est significative.

- Le test repose sur une statistique Z , ratio entre le coefficient estimé et son erreur standard (standard error) :

$$z_{\text{oss}} = b_j / \text{SE}(b_j)$$

Ce que cette formule dit, étape par étape :

- Sous H_0 , cette statistique suit approximativement une loi normale standard.
- On rejette H_0 au niveau de signification α (c'est-à-dire que x_j est considérée significative à ce niveau) si $|z_{\text{oss}}| > z_{\alpha/2}$.
- De façon équivalente, on rejette H_0 si $p\text{-value} = 2 \cdot P(Z > |z_{\text{oss}}|) < \alpha$.
- C'est exactement la même logique de décision par $p\text{-value}$ que dans tous les tests déjà vus en régression linéaire (Sessions 1 à 5).

9. Erreurs fréquentes et pièges à l'examen

- Confondre probabilité et cote (odds) — elles ne varient pas sur la même échelle (p entre 0 et 1, ODDS entre 0 et $+\infty$), et une variation de la cote n'est pas une variation identique de la probabilité.
- Interpréter e^{b_j} comme un changement direct de probabilité au lieu d'un rapport de cotes (odds ratio) — on ne peut affirmer que le **sens** du changement de probabilité, pas son ampleur exacte, à partir de b_j seul.
- Oublier de préciser "toutes les autres variables maintenues constantes" en interprétant b_j — l'interprétation n'est valable que toutes choses égales par ailleurs.
- Pour une variable dichotomique, comparer $x_j = 1$ à $x_j = 0$ en pensant qu'il s'agit d'un "+1 unité" comme pour une variable quantitative continue — la logique de la dérivation est identique, mais l'interprétation porte sur deux catégories, pas sur une unité de mesure.
- Croire qu'un b_j non nul suffit à conclure que x_j a un effet dans la population — il faut toujours passer par le test sur le coefficient individuel (Section 8).

10. À retenir absolument

À retenir :

- ODDS = $p/(1-p)$; correspondance croissante avec p ; le modèle logit modélise le **log** de la cote comme fonction linéaire des x .
- $\log(\hat{p}/(1-\hat{p})) = b_0 + b_1x_1 + \dots + b_px_p$, estimé par maximum de vraisemblance.
- e^{b_j} = rapport de cotes (odds ratio), toutes les autres variables maintenues constantes ; variable quantitative → effet d'une hausse d'une unité ; variable dichotomique → effet de $x_j=1$ vs $x_j=0$.
- $b_j > 0$ → cote (et probabilité) plus élevée ; $b_j < 0$ → cote (et probabilité) plus faible.
- Test individuel : $z_{\text{oss}} = b_j/\text{SE}(b_j)$, comparé à $z_{\alpha/2}$, ou $p\text{-value} < \alpha$ → même logique que pour la régression linéaire.

Points de vigilance

Attention : les slides ne détaillent pas le calcul du maximum de vraisemblance (Maximum Likelihood Estimation) lui-même — il faut savoir que c'est la méthode utilisée et que R la met en œuvre, sans avoir à la calculer à la main.