

Session 5. Les modèles de régression pour données de panel

À la fin de cette session, vous devez être capable de : reconnaître des données de panel (panel data, aussi appelées longitudinal data) et expliquer pourquoi une régression classique ne convient généralement pas pour ce type de données ; écrire l'équation du modèle à effets fixes (Fixed Effects Model, FEM) et du modèle à effets aléatoires (Random Effects Model, REM) ; expliquer ce que représentent l'erreur individuelle (individual-specific error) et l'erreur idiosyncratique (idiosyncratic error) ; et utiliser le test de Hausman (Hausman test) pour choisir entre FEM et REM.

Plan

1. Qu'est-ce qu'une donnée de panel
2. Pourquoi une régression classique ne fonctionne pas sur des données de panel
3. La solution simple mais fausse : le Pooling Model
4. Solution 1 : le modèle à effets fixes (FEM)
5. Solution 2 : le modèle à effets aléatoires (REM)
6. Comprendre les deux morceaux de l'erreur (individuel vs. idiosyncratique)
7. Choisir entre FEM et REM : le test de Hausman
8. Ajouter plusieurs variables explicatives
9. Erreurs Fréquentes et Pièges à l'Examen
10. À Retenir Absolument

1. Qu'est-ce qu'une donnée de panel

- Jusqu'ici dans ce cours, la plupart des données utilisées étaient des **données en coupe transversale (cross-sectional)** : plusieurs unités différentes (personnes, entreprises, pays), chacune observée **une seule fois**.
- Une **donnée de panel (panel data)**, aussi appelée **donnée longitudinale (longitudinal data)**, est différente : elle a **à la fois** une dimension transversale **et** une dimension temporelle, en même temps.
- On a n unités statistiques (par exemple des pays, des entreprises, des individus).
- Chaque unité est observée plusieurs fois, à T instants différents dans le temps.
- On obtient donc $n \cdot T$ observations au total, pour chaque variable.

Exemple (tiré des slides) : 5 pays ($n = 5$), chacun observé sur le PIB et le taux de chômage, chaque année de 1991 à 2020 ($T = 30$ ans). Pour chaque variable, cela fait $n \cdot T = 5 \cdot 30 = 150$ valeurs.

Exemple supplémentaire (analogie) : imaginez que vous suiviez les notes de 30 étudiants ($n = 30$) à chaque semestre, pendant 3 ans ($T = 6$ semestres). Vous avez alors $n \cdot T = 180$ observations de la variable "note". Chaque étudiant a sa propre trajectoire dans le temps, mais on observe aussi des différences entre étudiants à un même semestre : c'est exactement la double dimension (transversale + temporelle) qui caractérise une donnée de panel.

- Ce cours ne couvre que les **panels équilibrés (balanced panels)** :
- "Équilibré" signifie que chaque unité est observée à chacun des T instants, sans aucune valeur manquante.
- Un panel équilibré avec n unités et T instants a donc toujours exactement $n \times T$ observations par variable.
- Les panels peuvent avoir des formes très différentes, mais les mêmes outils s'appliquent toujours :
- beaucoup d'unités, peu d'instant (ex : 100 000 ménages suivis pendant 5 ans), ou

- peu d'unités, beaucoup d'instants (ex : 5 pays suivis chaque mois pendant 20 ans).

2. Pourquoi une régression classique ne fonctionne pas sur des données de panel

- Comme la même unité est observée plusieurs fois, ses observations successives ne sont généralement **pas indépendantes** les unes des autres dans le temps.
- Cela viole une des hypothèses de base de la régression linéaire vue en Session 1 : **les erreurs doivent être non corrélées entre elles**.
- Conclusion : le modèle de régression linéaire classique que vous connaissez déjà **ne convient généralement pas** aux données de panel, précisément à cause de cette structure d'observations répétées par unité.
- Bonne nouvelle malgré tout : la structure de panel offre aussi un moyen de mieux traiter un problème classique de la régression, les **corrélations fallacieuses (spurious correlations)**, qu'une simple coupe transversale ne permet pas de résoudre.

Corrélation fallacieuse (spurious correlation) — rappel : un effet apparent de X sur Y qui est en réalité causé par une variable de contrôle absente du modèle, mais corrélée à la fois avec X et avec Y.

Exemple des maisons côtières : n maisons en bord de mer, X = distance à la côte, Y = prix au mètre carré. Une régression simple de Y sur X seul donne une pente **positive** et significative, ce qui suggère "plus loin de la côte = plus cher" — ce qui semble illogique. En ajoutant Z = âge de la maison, le coefficient de X devient négatif et significatif. Pourquoi ? Les maisons récentes se trouvent justement plus loin de la côte (restrictions de construction sur le littoral), et les maisons récentes sont aussi plus chères. Une fois l'âge maintenu constant, s'éloigner de la côte est réellement associé à un prix **plus bas**. Les modèles pour données de panel attaquent ce même problème de variable omise de façon structurée, en utilisant les observations répétées de chaque unité pour neutraliser les caractéristiques inobservées et constantes dans le temps de cette unité — même celles qu'on ne peut jamais mesurer directement (comme "à quel point cette maison précise est désirable").

3. La solution simple mais fausse : le Pooling Model

- Notation pour le cas simple (une seule variable X, une seule variable Y) : x_{it} , y_{it} , pour l'unité $i = 1, \dots, n$ et l'instant $t = 1, \dots, T$.
- L'équation générale de régression pour données de panel ressemble presque exactement à une équation de régression ordinaire :

$$Y_{it} = \alpha + \beta x_{it} + u_{it}$$

où :

- Y_{it} est la variable dépendante (aléatoire), pour l'unité i à l'instant t
- x_{it} est la valeur observée de la variable explicative, pour l'unité i à l'instant t
- u_{it} est le terme d'erreur aléatoire pour l'unité i à l'instant t
- α , β sont des paramètres inconnus, supposés constants entre les unités et dans le temps (β décrit toujours la relation entre x et Y , exactement comme avant)

Ce que cette équation dit, étape par étape :

- Chaque couple unité-instant (i, t) a son propre point de données x_{it}, Y_{it} .
- Les mêmes α et β s'appliquent à toutes les unités et à tous les instants — rien n'est encore spécifique à une unité en particulier.
- Tout ce qui rend l'unité i différente de l'unité j est simplement versé, sans distinction, dans le terme d'erreur u_{it} .

Pooling Model : l'approche la plus simple (et généralement inadéquate) — traiter les $n \cdot T$ observations du panel comme si c'étaient $n \cdot T$ unités complètement différentes et sans lien entre elles. Elle ignore entièrement la structure temporelle et estime α et β par les moindres carrés ordinaires (ordinary least squares, OLS), exactement comme une régression classique en coupe transversale.

- Pourquoi c'est généralement faux : en ignorant quelles observations appartiennent à la même unité, le Pooling Model ne respecte pas les hypothèses de la régression (en particulier celle des erreurs non corrélées), et il réintroduit le même risque de variable omise que dans l'exemple des maisons côtières.
- Deux modèles dédiés corrigent ce problème en **séparant le terme d'erreur u_{it} en deux morceaux**, pour traiter explicitement les différences entre unités au lieu de les mélanger dans une seule erreur : le **modèle à effets fixes (Fixed Effects Model, FEM)** et le **modèle à effets aléatoires (Random Effects Model, REM)**. Ils ne diffèrent que par ce qu'ils supposent sur cette séparation.

4. Solution 1 : le modèle à effets fixes (Fixed Effects Model, FEM)

Fixed Effects Model (FEM) : sépare l'erreur en $u_{it} = \mu_i + \varepsilon_{it}$, où μ_i est un effet fixe de l'unité i — constant dans le temps et déterministe (pas aléatoire) — et ε_{it} est un terme d'erreur aléatoire avec les propriétés habituelles de la régression.

- μ_i se comporte comme un paramètre inconnu (un par unité) et capture l'**hétérogénéité inobservable (unobservable heterogeneity)** entre les unités — voyez-le comme "tout ce qui caractérise l'unité i , qui ne change jamais dans le temps, et que l'on n'a pas mesuré."
- ε_{it} se comporte exactement comme le terme d'erreur d'une régression ordinaire (moyenne nulle, variance constante, non corrélé).

$$Y_{it} = \alpha + \beta x_{it} + \mu_i + \varepsilon_{it} \quad (\text{de façon équivalente : } Y_{it} = \alpha_i + \beta x_{it} + \varepsilon_{it}, \text{ avec } \alpha_i := \alpha + \mu_i)$$

Ce que cette équation dit, étape par étape :

- On part de l'équation du Pooling Model, puis on ajoute un terme supplémentaire, μ_i , qui ne dépend que de l'unité observée.
- De façon équivalente, on peut fusionner α et μ_i en une seule **ordonnée à l'origine propre à chaque unité (unit-specific intercept) α_i** — chaque unité a donc, en pratique, sa propre "ligne de départ", tout en partageant la même pente β .
- Les paramètres à estimer sont $\alpha, \beta, \mu_1, \dots, \mu_n$ (ou, de façon équivalente, $\alpha_1, \dots, \alpha_n, \beta$) — estimés par les moindres carrés (OLS) appliqués à des transformations appropriées des données.
- Estimer $\mu_1, \dots, \mu_n$ est généralement **instrumental** : ce n'est pas le vrai objectif. Leur rôle est d'absorber l'effet individuel inobservé de chaque unité, pour que β — l'effet de x sur Y qui nous intéresse réellement — soit purgé de l'hétérogénéité due aux variables non incluses dans le modèle.
- Analogie utile : imaginez n entreprises représentées par n droites parallèles sur un même graphique (Y en fonction de x). Toutes les droites ont la même pente β , mais chacune part d'une hauteur différente (son propre α_i) — cette hauteur de départ, c'est μ_i .
- En R : `p1m(Y ~ X, data = ..., model = "within")` estime le FEM. Sa sortie "Coefficients" indique β , à lire exactement comme un coefficient de régression ordinaire (estimation, erreur standard, valeur du t ,

p-value). L'ordonnée à l'origine commune α n'est pas affichée directement ; les ordonnées individuelles α_i peuvent être extraites séparément avec `fixef()`.

Exemple travaillé (données Grunfeld) : $n = 10$ entreprises, $T = 20$ ans, $Y = \text{inv}$ (investissement), $x = \text{value}$ (valeur de l'entreprise). ``plm(inv ~ value, data = GR, model = "within")`` donne un β estimé ≈ 0.19 , très significatif ($p < 2.2 \cdot 10^{-16}$). Lecture : une hausse d'une unité de la valeur d'une entreprise est associée, en moyenne, à une hausse estimée de 0.19 unité de son investissement, une fois les caractéristiques propres et constantes dans le temps de chaque entreprise neutralisées.

5. Solution 2 : le modèle à effets aléatoires (Random Effects Model, REM)

Random Effects Model (REM) : utilise la même séparation de l'erreur $u_{it} = \mu_i + \varepsilon_{it}$, mais μ_i est maintenant un **effet individuel** de l'unité i , constant dans le temps et **aléatoire** (et non plus un paramètre fixe) ; μ_i et ε_{it} doivent tous les deux être non corrélés avec les variables explicatives.

- L'équation est identique à celle du FEM :

$$Y_{it} = \alpha + \beta x_{it} + \mu_i + \varepsilon_{it}$$

Ce qui change par rapport au FEM, étape par étape :

- μ_i n'est plus "un nombre fixe à estimer par unité" — c'est maintenant considéré comme un morceau aléatoire et inobservé de l'erreur.
- Comme μ_i est une variable aléatoire partagée par toutes les observations d'une même unité i , les erreurs globales u_{it} de cette unité ne sont plus non corrélées dans le temps (contrairement à ε_{it} , qui reste non corrélée comme d'habitude).
- Les **seuls** paramètres réellement estimés sont α et β — pas n valeurs séparées de μ_i . C'est tout l'intérêt du REM : moins de paramètres à estimer.
- L'estimation nécessite une version généralisée des moindres carrés (et non des OLS classiques) pour tenir compte de cette corrélation à l'intérieur de chaque unité. En R : `plm(Y ~ X, data = ..., model = "random")` (utilise la transformation de Swamy-Arora).

Mêmes données Grunfeld, effets aléatoires : ``plm(inv ~ value, data = GR, model = "random")`` donne un β estimé ≈ 0.166 , également très significatif. La sortie décompose en plus la variance inexpliquée en : composante idiosyncratique $\approx 55.6\%$ de la variance, composante individuelle $\approx 44.4\%$. La sortie du FEM n'a pas cette décomposition — c'est une information propre au REM.

6. Comprendre les deux morceaux de l'erreur (individuel vs. idiosyncratique)

Les deux modèles découpent u_{it} en les deux mêmes ingrédients conceptuels. Savoir lire correctement leur taille relative est une question d'examen classique, en particulier sur la sortie du REM (car seul le REM affiche les variances explicitement).

Erreur individuelle (individual-specific error, μ_i) : caractéristiques constantes dans le temps et propres à chaque unité ; capture les différences persistantes entre individus. Non observées directement ni incluses dans le modèle, mais elles influencent quand même Y .

- Exemples tirés des slides : la compétence innée d'un travailleur, la culture d'entreprise d'une firme, la qualité institutionnelle d'un pays.
- Comment lire sa variabilité :
- grande → de grandes différences persistantes entre individus jouent un rôle important.
- petite → les individus sont relativement similaires une fois les variables observées prises en compte.

Erreur idiosyncratique (idiosyncratic error, ϵ_{it}) : fluctuations aléatoires qui varient à la fois selon les individus et dans le temps ; capture des chocs temporaires ou des erreurs de mesure. Reflète la variabilité d'un même individu au fil du temps.

- Exemples tirés des slides : des changements de productivité à court terme, des chocs de marché temporaires, du bruit de mesure dans les données.
- Comment lire sa variabilité :
- grande → forte imprévisibilité au niveau de chaque observation individuelle.
- petite → les résultats sont relativement stables dans le temps pour chaque individu.

En comparant les deux variances :

- La variance individuelle domine → la majeure partie de la variabilité vient des différences **entre** individus. Cela peut indiquer une variable importante, inobservée et constante dans le temps, absente du modèle — mais ce **n'est pas automatiquement un problème** : les coefficients restent fiables. Trouver et ajouter cette variable manquante, si c'est possible, rendrait probablement le modèle plus informatif, c'est tout.
- La variance idiosyncratique domine → la majeure partie de la variabilité vient des fluctuations **internes** à chaque individu au fil du temps.

7. Choisir entre FEM et REM : le test de Hausman (Hausman test)

- En pratique, les estimations du FEM et du REM sont souvent proches (0.19 contre 0.166 dans l'exemple Grunfeld ci-dessus).
- Le REM est préférable **quand il est valide**, car il estime beaucoup moins de paramètres (seulement α , β , contre α , β plus n valeurs séparées de μ_i pour le FEM) — le FEM perd des degrés de liberté (degrees of freedom) à cause de tous ces paramètres d'effets individuels supplémentaires.
- Mais la validité du REM repose sur une vraie hypothèse : μ_i doit être non corrélé avec les variables explicatives.
- Si cette hypothèse est **fausse** : les estimations du REM deviennent **non convergentes (inconsistent)**, donc peu fiables — et une procédure non convergente est écartée.
- Si cette hypothèse est **vraie** : les estimations du REM sont convergentes **et** plus efficaces (efficient) que celles du FEM.

Test de Hausman (Hausman test) : le test utilisé pour choisir entre FEM et REM.

H_0 : les hypothèses du REM sont vérifiées → ses estimations sont convergentes et plus efficaces que celles du FEM.

H_1 : les hypothèses du REM ne sont pas vérifiées → ses estimations sont non convergentes.

La règle de décision, étape par étape (même logique de p-value que pour tous les autres tests du cours) :

- Choisir un seuil de signification α (par exemple 0.05).
- Calculer le test et sa p-value (en R : `phtest(mod_fem, mod_rem)` du package `plm` — l'ordre des deux modèles n'a pas d'importance).
- Rejeter H_0 (p-value $\leq \alpha$) → **choisir le FEM**.
- Ne pas rejeter H_0 (p-value $> \alpha$) → **choisir le REM**.

Exemple Grunfeld, deux variables explicatives (value et capital) : ``phtest(mod3, mod4)`` renvoie chi-carré = 2.3304, ddl = 2, p-value = 0.3119. Au seuil habituel de 5%, H_0 n'est pas rejetée → on utilise ici le REM (plus efficace).

8. Ajouter plusieurs variables explicatives

- Le FEM comme le REM s'étendent à plusieurs variables explicatives (quantitatives et/ou catégorielles) exactement comme la régression ordinaire passe du cas simple au cas multiple — il suffit d'ajouter des termes x supplémentaires :

$$Y_{it} = \alpha + \beta_1 x_{1it} + \beta_2 x_{2it} + \dots + \beta_p x_{pit} + \mu_i + \varepsilon_{it}$$

où :

- pour le FEM → μ_i est déterministe, ε_{it} est aléatoire
- pour le REM → μ_i et ε_{it} sont tous les deux aléatoires

Ce que cette équation dit, étape par étape :

- C'est exactement la même logique que passer d'une régression simple à une régression multiple en Session 1 : on ajoute simplement des variables $x_{1it}, x_{2it}, \dots, x_{pit}$, chacune avec son propre coefficient $\beta_1, \dots, \beta_p$.
- μ_i et ε_{it} jouent exactement le même rôle que dans le cas à une seule variable explicative — seule leur nature (fixe ou aléatoire) dépend du choix FEM/REM.
- Concrètement (exemple Grunfeld ci-dessus) : on pourrait avoir Y = investissement, x_1 = value (valeur de l'entreprise) et x_2 = capital (stock de capital), et interpréter chaque β_j comme l'effet marginal de x_j sur l'investissement, toutes choses égales par ailleurs — exactement comme en régression multiple classique.
- Rien d'autre ne change : on ajuste toujours le modèle avec `plm()` (`model = "within"` ou `model = "random"`), la sortie se lit de la même façon, et le test de Hausman continue de comparer les deux ajustements.
- Les transformations (logarithmes, puissances) et les interactions entre variables (vues en Session 3) peuvent être introduites exactement comme en régression multiple ordinaire.

9. Erreurs fréquentes et pièges à l'examen

- Faire une régression poolée classique sur des données de panel sans vérifier si l'hétérogénéité entre unités ne fausse pas l'effet estimé — le Pooling Model est mathématiquement une simple régression ordinaire, et hérite donc du même risque de variable omise que l'exemple des maisons côtières.
- Croire que le FEM et le REM estiment toujours le même ensemble de paramètres : le FEM estime n valeurs de μ_i comme des paramètres fixes (en plus de α, β) ; le REM traite μ_i comme un terme aléatoire inobservé et n'estime directement que α et β .
- Oublier que la convergence (consistency) du REM exige que μ_i soit non corrélé avec les variables explicatives — c'est une vraie hypothèse testable (via Hausman), pas quelque chose que le REM obtient gratuitement.
- Mal lire la règle de décision du test de Hausman : rejeter H_0 → les hypothèses du REM échouent → passer au FEM. (Facile à inverser par erreur — rejeter H_0 ne signifie PAS "garder le REM".)
- Considérer qu'une part élevée de la variance de l'erreur individuelle est le signe d'un mauvais modèle : cela signifie simplement que des différences persistantes entre unités expliquent l'essentiel de la variabilité inexpliquée ; cela peut, ou non, justifier l'ajout d'une autre variable.
- Utiliser une régression classique en coupe transversale sur des données chronologiques ou de panel sans vérifier au préalable la corrélation entre observations d'une même unité.

10. À retenir absolument

À retenir :

- Donnée de panel = dimension transversale + dimension temporelle ; n unités $\times$ T instants ; panel équilibré $\rightarrow$ exactement $n \cdot T$ observations par variable.
- Pooling Model = régression OLS ordinaire sur les $n \cdot T$ observations, en ignorant la structure de panel $\rightarrow$ même risque de variable omise qu'une simple coupe transversale.
- FEM : $u_{it} = \mu_i + \varepsilon_{it}$, μ_i fixe/déterministe, une ordonnée à l'origine par unité estimée ('model = "within").
- REM : même séparation, μ_i aléatoire et non corrélé avec les x , seuls α et β sont estimés ('model = "random") $\rightarrow$ moins de paramètres, plus efficace si valide.
- Erreur individuelle μ_i = différences persistantes et constantes dans le temps entre unités ; erreur idiosyncratique ε_{it} = fluctuation propre à chaque unité, variable dans le temps.
- Test de Hausman : H_0 = REM valide. Rejeter $H_0 \rightarrow$ utiliser le FEM. Ne pas rejeter $H_0 \rightarrow$ utiliser le REM.

Points de vigilance

Attention : le cours ne détaille pas les calculs mathématiques du test de Hausman lui-même ("we won't go into the mathematical details"). Il faut connaître son objectif, ses deux hypothèses, et savoir lire la décision à partir de la p-value — vous ne serez pas amené à le calculer à la main.