Session 7. Modèle logit, significativité, prédiction et qualité du modèle

À la fin de cette session, vous devez être capable de : tester la significativité conjointe d'un groupe de variables et du modèle entier avec le test du chi-carré (chi-square test / LRT) ; calculer une prédiction (log-odds, cote, probabilité, valeur de Y) à partir d'un modèle logit estimé ; et évaluer la qualité d'un modèle logit avec le taux de bonnes prédictions et l'AIC.

Plan

1. Pourquoi un nouveau test, au-delà du test individuel
2. Deux questions, test partiel et test global
3. La déviance résiduelle (residual deviance)
4. La statistique du chi-carré et la règle de décision
5. Prédiction à partir d'un modèle logit
6. Évaluer la qualité d'un modèle, taux de bonnes prédictions et AIC
7. Exemple travaillé complet en R
8. Erreurs fréquentes et pièges à l'examen
9. À retenir absolument

1. Pourquoi un nouveau test, au-delà du test individuel

- Le test vu en Session 6 (statistique Z) ne teste qu'**un seul** coefficient à la fois.
- Comme en régression linéaire multiple, on a aussi besoin de savoir si **plusieurs** coefficients sont significatifs **ensemble**, ou si le modèle dans son entier apporte quelque chose par rapport à l'absence de modèle.
- Ces questions se répondent avec des tests basés sur des statistiques qui suivent (approximativement) une loi du chi-carré (chi-square distribution).

2. Deux questions, test partiel et test global

- **Question 1 (test sur un groupe de variables) :** dans un modèle avec x_1, ..., x_q, x_{q+1}, ..., x_p, les variables x_{q+1}, ..., x_p sont-elles conjointement significatives ? Autrement dit, entre les deux modèles emboîtés (nested models) $M_{réd}$ (seulement x_1, ..., x_q) et M_{compl} (toutes les variables x_1, ..., x_p), lequel choisir, sachant que le second est plus complexe ?
- **Question 2 (test global) :** le modèle avec x_1, ..., x_p est-il globalement significatif ? Autrement dit, doit-on préférer ce modèle au modèle nul (null model), celui sans aucune variable explicative ?
- La question 2 est un cas particulier de la question 1, avec $q = 0$ ($M_{réd}$ = modèle nul).
- Les hypothèses correspondantes :

> **Test partiel (sur un groupe de variables) :** $H_0 : \beta_{q+1} = \beta_{q+2} = \ldots = \beta_p = 0$ contre H_1 : au moins un de ces coefficients est différent de 0.

> **Test global (du modèle entier) :** $H_0 : \beta_1 = \beta_2 = \ldots = \beta_p = 0$ contre H_1 : au moins un des coefficients est différent de 0.

- On les appelle respectivement le **test du chi-carré partiel** et le **test du chi-carré global**.

3. La déviance résiduelle (residual deviance)

- La statistique de test se construit à partir de deux quantités associées à un modèle logit estimé M :

> **Déviance résiduelle (residual deviance) :** RES.DEV = $-2 \cdot \log L(M)$, où $L(M)$ est le maximum de vraisemblance (maximum likelihood) associé au modèle M.

> **Degrés de liberté résiduels (residual degrees of freedom) :** $n - p - 1$, où n est la taille de l'échantillon et p le nombre de variables explicatives du modèle.

- Plus la déviance résiduelle est faible, mieux le modèle s'ajuste aux données (dans la même logique que la somme des carrés résiduels en régression linéaire).

4. La statistique du chi-carré et la règle de décision

- **Test sur un groupe de variables :**

$$\chi^2 = \text{RES.DEV.}(M_{\text{réd}}) - \text{RES.DEV.}(M_{\text{compl}})$$

- Sous H_0, cette statistique suit approximativement une loi du chi-carré à $p - q$ degrés de liberté (la différence entre les degrés de liberté résiduels des deux modèles).
- **Test global :**

$$\chi^2 = \text{RES.DEV.}(M_{\text{null}}) - \text{RES.DEV.}(M_{\text{compl}})$$

- Sous H_0, cette statistique suit approximativement une loi du chi-carré à p degrés de liberté (puisque $q = 0$ dans le modèle nul).

Ce que ces formules disent, étape par étape :

- Dans les deux cas, on calcule la différence de déviance résiduelle entre le modèle réduit et le modèle complet.
- Si le modèle complet apporte vraiment quelque chose, sa déviance résiduelle est nettement plus faible que celle du modèle réduit, donc χ^2 est grand.
- On rejette H_0 au niveau α si $\chi^2_{\text{oss}} > \chi^2_{\alpha}$ (le quantile de la loi du chi-carré appropriée), ou de façon équivalente si p-value = $P(\chi^2 > \chi^2_{\text{oss}}) < \alpha$.

> **LRT (Likelihood Ratio Test) :** autre nom pour ces tests du chi-carré, car ils reposent sur la fonction de vraisemblance (likelihood function).

- Comme en régression linéaire, le modèle logit peut aussi inclure des transformations de variables explicatives et des interactions entre variables explicatives — les objectifs et procédures sont les mêmes que pour la régression linéaire (Sessions 1 à 3).

5. Prédiction à partir d'un modèle logit

- À partir de l'équation estimée, on peut prédire, pour des valeurs fixées des variables explicatives :
- le log-odds de l'événement Y = 1 (ou de sa négation)
- la cote (odds) de l'événement Y = 1 (ou de sa négation)
- la probabilité de l'événement Y = 1 (ou de sa négation)
- la valeur de Y elle-même (0 ou 1)

$$\log(\hat{p}_0 / (1 - \hat{p}_0)) = b_0 + b_1 x_1^0 + \ldots + b_p x_p^0$$

Ce que cette formule dit, étape par étape :

- On fixe les valeurs des variables explicatives pour lesquelles on veut prédire, $x_1 = x_1^0$, ..., $x_p = x_p^0$.
- La prédiction du log-odds s'obtient par simple substitution dans l'équation estimée.
- La prédiction de la cote s'obtient en prenant l'exponentielle du log-odds prédit.
- La prédiction de la probabilité s'obtient ensuite via la relation entre cote et probabilité (Section 1 de la Session 6).
- En pratique, R fournit directement la prédiction avec la fonction `predict`.
- Pour prédire la valeur de Y (0 ou 1), on utilise généralement (mais pas obligatoirement) un seuil de 0.5 :
- $\hat{y}_0 = 1$ si $\hat{p}_0 \geq 0.5$
- $\hat{y}_0 = 0$ si $\hat{p}_0 < 0.5$

6. Évaluer la qualité d'un modèle, taux de bonnes prédictions et AIC

- Pour évaluer la capacité prédictive d'un modèle logit, on compare les valeurs prédites de Y (0/1) pour les unités de l'échantillon avec les valeurs réellement observées.
- La proportion (ou le pourcentage) de "bonnes" prédictions (valeur prédite et valeur observée toutes deux égales à 1, ou toutes deux égales à 0) donne une indication de la qualité prédictive du modèle.

AIC (Akaike Information Criterion) : indicateur descriptif de la qualité globale d'un modèle logit, défini par AIC = $-2 \cdot \log L(M) + 2(p+1)$, où $-2 \cdot \log L(M)$ est la déviance résiduelle du modèle et p le nombre de variables explicatives.

- L'AIC tient compte à la fois de la capacité explicative du modèle (via la déviance résiduelle) et de sa complexité (via p).
- Un modèle est considéré meilleur, selon ce critère, si son AIC est **plus faible**.

Attention : pour comparer des modèles emboîtés (nested models), l'outil le plus approprié reste le test du chi-carré partiel (Section 4), pas l'AIC seul — l'AIC est surtout utile pour comparer des modèles qui ne sont pas nécessairement emboîtés.

7. Exemple travaillé complet en R

> **Contexte (slides, exemple assurance) :** échantillon de 200 sinistres. HC = 1 si l'indemnisation est considérée élevée ("high compensation"), 0 sinon. AGE = âge du conducteur responsable. VC = catégorie du véhicule (A, B ou C). Modèle logit avec HC comme variable dépendante, AGE et VC comme variables explicatives.

- Sortie R (`glm(HC~AGE+VC, data=CL, binomial(logit))`) :
- Coefficient AGE = -0.0389, significatif au seuil 0.05 (mais pas au seuil 0.01). Comme $e^{-0.0389} = 0.9618$, une année supplémentaire d'âge est associée à une baisse estimée d'environ 3.82% de la cote d'avoir un sinistre élevé, catégorie de véhicule maintenue constante.
- Coefficient VCB (catégorie B vs A) = 1.1268, significatif au seuil 0.05. Comme $e^{1.1268} = 3.0858$, la cote estimée d'un sinistre élevé pour un véhicule de catégorie B est environ 3 fois celle d'un véhicule de catégorie A, âge maintenu constant.
- Coefficient VCC (catégorie C vs A) : interprétation analogue, significatif à tout seuil raisonnable.
- Déviance résiduelle = 159.84 ; AIC = 167.84 = 159.84 + 2×(p+1) avec p = 3.
- **Test global** (comparaison avec le modèle nul, `anova(model0, model1, test="Chisq")`) : $\chi^2 = 77.344$, 3 degrés de liberté, p-value $< 2.2 \cdot 10^{-16}$ → le modèle est globalement significatif, H_0 rejetée.
- **Test partiel sur VC** (comparaison entre le modèle avec AGE seul et le modèle avec AGE + VC, `anova(model2, model1, test="Chisq")`) : $\chi^2 = 69.202$, 2 degrés de liberté (VC entre avec 2 dummies), p-value ≈ 0 → VC est globalement significative dans ce modèle, elle améliore nettement la capacité explicative par rapport au modèle avec AGE seul.
- **Prédiction** pour un sinistre catégorie B, conducteur de 50 ans (50 est dans l'intervalle des âges observés, la prédiction est donc raisonnable) :
- `predict(model1, data.frame(AGE=50, VC="B"), type="response")` → probabilité prédite ≈ 0.1863.
- Sans l'option `type="response"`, `predict` renvoie le log-odds prédit (≈ −1.4739) ; en prenant l'exponentielle on retrouve la cote prédite (≈ 0.2290), cohérente avec 0.1863/(1−0.1863) ≈ 0.2290.
- **Évaluation de la qualité prédictive** (matrice de confusion, seuil 0.5 sur les 200 sinistres de l'échantillon) :
- 128 cas prédits "pas de sinistre élevé" et effectivement pas de sinistre élevé.
- 40 cas prédits "sinistre élevé" et effectivement un sinistre élevé.
- Au total 168 cas sur 200 correctement prédits, soit 84% de bonnes prédictions.

8. Erreurs fréquentes et pièges à l'examen

- Utiliser le test individuel (statistique Z, Session 6) pour tester la significativité d'un **groupe** de variables au lieu du test du chi-carré — le test individuel ne teste qu'un coefficient à la fois.
- Oublier que le test global n'est qu'un cas particulier du test partiel, avec le modèle nul comme modèle réduit (q = 0).
- Comparer directement deux déviances résiduelles sans tenir compte des degrés de liberté correspondants (p − q pour le test partiel, p pour le test global).
- Confondre AIC et test du chi-carré partiel : l'AIC compare des modèles (emboîtés ou non) par un seul chiffre à minimiser, le test du chi-carré partiel donne une p-value et une décision statistique formelle pour des modèles emboîtés.

- Oublier de vérifier que les valeurs des variables explicatives utilisées pour une prédiction sont raisonnables (dans l'intervalle des données observées), exactement comme en régression linéaire.
- Interpréter directement le log-odds prédit ou la cote prédite comme une probabilité — il faut repasser par la relation cote/probabilité (ou utiliser `type="response"` dans R) pour obtenir une probabilité.

9. À retenir absolument

À retenir :
• Test sur un groupe de variables (test partiel) et test du modèle entier (test global) sont deux tests du chi-carré (LRT), basés sur la différence de déviance résiduelle entre modèle réduit et modèle complet.
• χ^2 = RES.DEV.(réduit) − RES.DEV.(complet), ddl = différence des ddl résiduels des deux modèles ; rejeter H_0 si $\chi^2_{oss} > \chi^2_{\alpha}$ ou p-value < α.
• AIC = $-2\log L(M) + 2(p+1)$; modèle meilleur si AIC plus faible ; utile surtout pour comparer des modèles non nécessairement emboîtés.
• Prédiction, log-odds par substitution → cote par exponentielle → probabilité via la relation cote/probabilité ; valeur de Y prédite = 1 si $\hat{p} \geq 0.5$ (seuil par défaut).
• Qualité prédictive évaluée par le taux de bonnes prédictions (matrice de confusion, valeurs prédites vs observées).

Points de vigilance

Attention : le seuil de 0.5 pour prédire $\hat{y}$ à partir de $\hat{p}$ est celui utilisé par défaut dans les slides, mais elles précisent explicitement qu'un seuil différent reste possible selon le contexte ("it is also possible to use a different threshold") — ne pas traiter 0.5 comme une règle absolue et fixe.