

Session 7. Modèle logit, significativité, prédiction et qualité du modèle

À la fin de cette session, vous devez être capable de : tester la significativité conjointe d'un groupe de variables et du modèle entier avec le test du chi-carré (chi-square test / LRT) ; calculer une prédiction (log-odds, cote, probabilité, valeur de Y) à partir d'un modèle logit estimé ; et évaluer la qualité d'un modèle logit avec le taux de bonnes prédictions et l'AIC.

Plan

1. Pourquoi un nouveau test, au-delà du test individuel
2. Deux questions, test partiel et test global
3. La déviance résiduelle (residual deviance)
4. La statistique du chi-carré et la règle de décision
5. Prédiction à partir d'un modèle logit
6. Évaluer la qualité d'un modèle, taux de bonnes prédictions et AIC
7. Exemple travaillé complet en R
8. Erreurs fréquentes et pièges à l'examen
9. À retenir absolument

1. Pourquoi un nouveau test, au-delà du test individuel

- Le test vu en Session 6 (statistique Z) ne teste qu'un **seul** coefficient à la fois.
- Comme en régression linéaire multiple, on a aussi besoin de savoir si **plusieurs** coefficients sont significatifs **ensemble**, ou si le modèle dans son entier apporte quelque chose par rapport à l'absence de modèle.
- Ces questions se répondent avec des tests basés sur des statistiques qui suivent (approximativement) une loi du chi-carré (chi-square distribution).

2. Deux questions, test partiel et test global

- **Question 1 (test sur un groupe de variables)** : dans un modèle avec $x_1, \dots, x_q, x_{q+1}, \dots, x_p$, les variables $x_{q+1}, \dots, x_p$ sont-elles conjointement significatives ? Autrement dit, entre les deux modèles emboîtés (nested models) $M_{\text{réd}}$ (seulement $x_1, \dots, x_q$) et M_{compl} (toutes les variables $x_1, \dots, x_p$), lequel choisir, sachant que le second est plus complexe ?
- **Question 2 (test global)** : le modèle avec $x_1, \dots, x_p$ est-il globalement significatif ? Autrement dit, doit-on préférer ce modèle au modèle nul (null model), celui sans aucune variable explicative ?
- La question 2 est un cas particulier de la question 1, avec $q = 0$ ($M_{\text{réd}}$ = modèle nul).
- Les hypothèses correspondantes :

Test partiel (sur un groupe de variables) : $H_0 : \beta_{q+1} = \beta_{q+2} = \dots = \beta_p = 0$ contre H_1 : au moins un de ces coefficients est différent de 0.

Test global (du modèle entier) : $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ contre H_1 : au moins un des coefficients est différent de 0.

- On les appelle respectivement le **test du chi-carré partiel** et le **test du chi-carré global**.

3. La déviance résiduelle (residual deviance)

- La statistique de test se construit à partir de deux quantités associées à un modèle logit estimé M :

Déviance résiduelle (residual deviance) : $\text{RES.DEV} = -2 \cdot \log L(M)$, où $L(M)$ est le maximum de vraisemblance (maximum likelihood) associé au modèle M .

Degrés de liberté résiduels (residual degrees of freedom) : $n - p - 1$, où n est la taille de l'échantillon et p le nombre de variables explicatives du modèle.

- Plus la déviance résiduelle est faible, mieux le modèle s'ajuste aux données (dans la même logique que la somme des carrés résiduels en régression linéaire).

4. La statistique du chi-carré et la règle de décision

- Test sur un groupe de variables :**

$$\chi^2 = \text{RES.DEV.}(M_{\text{réd}}) - \text{RES.DEV.}(M_{\text{compl}})$$

Sous H_0 , cette statistique suit approximativement une loi du chi-carré à $p - q$ degrés de liberté (la différence entre les degrés de liberté résiduels des deux modèles).

Test global :

$$\chi^2 = \text{RES.DEV.}(M_{\text{null}}) - \text{RES.DEV.}(M_{\text{compl}})$$

- Sous H_0 , cette statistique suit approximativement une loi du chi-carré à p degrés de liberté (puisque $q = 0$ dans le modèle nul).

Ce que ces formules disent, étape par étape :

- Dans les deux cas, on calcule la différence de déviance résiduelle entre le modèle réduit et le modèle complet.
- Si le modèle complet apporte vraiment quelque chose, sa déviance résiduelle est nettement plus faible que celle du modèle réduit, donc χ^2 est grand.
- On rejette H_0 au niveau α si $\chi^2_{\text{oss}} > \chi^2_{\alpha}$ (le quantile de la loi du chi-carré appropriée), ou de façon équivalente si $p\text{-value} = P(\chi^2 > \chi^2_{\text{oss}}) < \alpha$.

LRT (Likelihood Ratio Test) : autre nom pour ces tests du chi-carré, car ils reposent sur la fonction de vraisemblance (likelihood function).

- Comme en régression linéaire, le modèle logit peut aussi inclure des transformations de variables explicatives et des interactions entre variables explicatives — les objectifs et procédures sont les mêmes que pour la régression linéaire (Sessions 1 à 3).

5. Prédiction à partir d'un modèle logit

- À partir de l'équation estimée, on peut prédire, pour des valeurs fixées des variables explicatives :
- le log-odds de l'événement $Y = 1$ (ou de sa négation)

- la cote (odds) de l'événement $Y = 1$ (ou de sa négation)
- la probabilité de l'événement $Y = 1$ (ou de sa négation)
- la valeur de Y elle-même (0 ou 1)

$$\log(\hat{p}_0 / (1 - \hat{p}_0)) = b_0 + b_1 x_1^0 + \dots + b_p x_p^0$$

Ce que cette formule dit, étape par étape :

- On fixe les valeurs des variables explicatives pour lesquelles on veut prédire, $x_1 = x_1^0, \dots, x_p = x_p^0$.
- La prédiction du log-odds s'obtient par simple substitution dans l'équation estimée.
- La prédiction de la cote s'obtient en prenant l'exponentielle du log-odds prédit.
- La prédiction de la probabilité s'obtient ensuite via la relation entre cote et probabilité (Section 1 de la Session 6).
- En pratique, R fournit directement la prédiction avec la fonction `predict`.
- Pour prédire la valeur de Y (0 ou 1), on utilise généralement (mais pas obligatoirement) un seuil de 0.5 :
- $\hat{y}_0 = 1$ si $\hat{p}_0 \geq 0.5$
- $\hat{y}_0 = 0$ si $\hat{p}_0 < 0.5$

6. Évaluer la qualité d'un modèle, taux de bonnes prédictions et AIC

- Pour évaluer la capacité prédictive d'un modèle logit, on compare les valeurs prédites de Y (0/1) pour les unités de l'échantillon avec les valeurs réellement observées.
- La proportion (ou le pourcentage) de "bonnes" prédictions (valeur prédite et valeur observée toutes deux égales à 1, ou toutes deux égales à 0) donne une indication de la qualité prédictive du modèle.

AIC (Akaike Information Criterion) : indicateur descriptif de la qualité globale d'un modèle logit, défini par $AIC = -2 \cdot \log L(M) + 2(p+1)$, où $-2 \cdot \log L(M)$ est la déviance résiduelle du modèle et p le nombre de variables explicatives.

- L'AIC tient compte à la fois de la capacité explicative du modèle (via la déviance résiduelle) et de sa complexité (via p).
- Un modèle est considéré meilleur, selon ce critère, si son AIC est **plus faible**.

Attention : pour comparer des modèles emboîtés (nested models), l'outil le plus approprié reste le test du chi-carré partiel (Section 4), pas l'AIC seul — l'AIC est surtout utile pour comparer des modèles qui ne sont pas nécessairement emboîtés.

7. Exemple travaillé complet en R

Contexte (slides, exemple assurance) : échantillon de 200 sinistres. $HC = 1$ si l'indemnisation est considérée élevée ("high compensation"), 0 sinon. AGE = âge du conducteur responsable. VC = catégorie du véhicule (A, B ou C). Modèle logit avec HC comme variable dépendante, AGE et VC comme variables explicatives.

- Sortie R (`glm(HC~AGE+VC, data=CL, binomial(logit))`):
- Coefficient $AGE = -0.0389$, significatif au seuil 0.05 (mais pas au seuil 0.01). Comme $e^{-0.0389} = 0.9618$, une année supplémentaire d'âge est associée à une baisse estimée d'environ 3.92% de la cote d'avoir un sinistre élevé, catégorie de véhicule maintenue constante.

- Coefficient VCB (catégorie B vs A) = 1.1268, significatif au seuil 0.05. Comme $e^{1.1268} = 3.0858$, la cote estimée d'un sinistre élevé pour un véhicule de catégorie B est environ 3 fois celle d'un véhicule de catégorie A, âge maintenu constant.
- Coefficient VCC (catégorie C vs A) : interprétation analogue, significatif à tout seuil raisonnable.

Déviance résiduelle = 159.84 ; AIC = 167.84 = 159.84 + 2×(p+1) avec p = 3.

Test global (comparaison avec le modèle nul, `anova(model0, model1, test="Chisq")`) : $\chi^2 = 77.344$, 3 degrés de liberté, p-value < $2.2 \cdot 10^{-16}$ → le modèle est globalement significatif, H_0 rejetée.

Test partiel sur VC (comparaison entre le modèle avec AGE seul et le modèle avec AGE + VC, `anova(model2, model1, test="Chisq")`) : $\chi^2 = 69.202$, 2 degrés de liberté (VC entre avec 2 dummies), p-value ≈ 0 → VC est globalement significative dans ce modèle, elle améliore nettement la capacité explicative par rapport au modèle avec AGE seul.

Prédiction pour un sinistre catégorie B, conducteur de 50 ans (50 est dans l'intervalle des âges observés, la prédiction est donc raisonnable) :

- `predict(model1, data.frame(AGE=50, VC="B"), type="response")` → probabilité prédite ≈ 0.1863.

Sans l'option `type="response"`, `predict` renvoie le log-odds prédit (≈ -1.4739) ; en prenant l'exponentielle on retrouve la cote prédite (≈ 0.2290), cohérente avec $0.1863/(1-0.1863) \approx 0.2290$.

Évaluation de la qualité prédictive (matrice de confusion, seuil 0.5 sur les 200 sinistres de l'échantillon) :

- 128 cas prédits "pas de sinistre élevé" et effectivement pas de sinistre élevé.
- 40 cas prédits "sinistre élevé" et effectivement un sinistre élevé.
- Au total 168 cas sur 200 correctement prédits, soit 84% de bonnes prédictions.

8. Erreurs fréquentes et pièges à l'examen

- Utiliser le test individuel (statistique Z, Session 6) pour tester la significativité d'un **groupe** de variables au lieu du test du chi-carré — le test individuel ne teste qu'un coefficient à la fois.
- Oublier que le test global n'est qu'un cas particulier du test partiel, avec le modèle nul comme modèle réduit (q = 0).
- Comparer directement deux déviations résiduelles sans tenir compte des degrés de liberté correspondants (p – q pour le test partiel, p pour le test global).
- Confondre AIC et test du chi-carré partiel : l'AIC compare des modèles (emboîtés ou non) par un seul chiffre à minimiser, le test du chi-carré partiel donne une p-value et une décision statistique formelle pour des modèles emboîtés.
- Oublier de vérifier que les valeurs des variables explicatives utilisées pour une prédiction sont raisonnables (dans l'intervalle des données observées), exactement comme en régression linéaire.
- Interpréter directement le log-odds prédit ou la cote prédite comme une probabilité — il faut repasser par la relation cote/probabilité (ou utiliser `type="response"` dans R) pour obtenir une probabilité.

9. À retenir absolument

À retenir :

- Test sur un groupe de variables (test partiel) et test du modèle entier (test global) sont deux tests du chi-carré (LRT), basés sur la différence de déviance résiduelle entre modèle réduit et modèle complet.
- $\chi^2 = \text{RES.DEV.}(\text{réduit}) - \text{RES.DEV.}(\text{complet})$, ddl = différence des ddl résiduels des deux modèles ; rejeter H_0 si $\chi^2_{\text{oss}} > \chi^2_{\alpha}$ ou p-value < α .
- AIC = $-2\log L(M) + 2(p+1)$; modèle meilleur si AIC plus faible ; utile surtout pour comparer des modèles non

nécessairement emboîtés.

- Prédiction, log-odds par substitution → cote par exponentielle → probabilité via la relation cote/probabilité ; valeur de Y prédite = 1 si $\hat{p} \geq 0.5$ (seuil par défaut).
- Qualité prédictive évaluée par le taux de bonnes prédictions (matrice de confusion, valeurs prédites vs observées).

Points de vigilance

Attention : le seuil de 0.5 pour prédire $\hat{y}$ à partir de $\hat{p}$ est celui utilisé par défaut dans les slides, mais elles précisent explicitement qu'un seuil différent reste possible selon le contexte ("it is also possible to use a different threshold") — ne pas traiter 0.5 comme une règle absolue et fixe.