

Session 8. Le modèle logit multinomial pour variable qualitative à plus de 2 catégories

À la fin de cette session, vous devez être capable de : reconnaître quand utiliser un modèle logit multinomial (multinomial logit model) plutôt qu'un modèle logit binaire ; écrire les $k-1$ équations du modèle par rapport à une catégorie de référence ; interpréter un coefficient estimé b_{ji} pour une variable quantitative ou dichotomique ; tester la significativité d'un coefficient individuel ; et calculer une prédiction de probabilités pour chaque catégorie.

Plan

1. Quand utiliser le modèle multinomial
2. Équations théoriques du modèle
3. Estimation des paramètres
4. Interpréter un coefficient, cas d'une variable quantitative
5. Interpréter un coefficient, cas d'une variable dichotomique
6. Test sur un coefficient individuel
7. Prédiction des probabilités
8. Exemple travaillé complet en R
9. Erreurs fréquentes et pièges à l'examen
10. À retenir absolument

1. Quand utiliser le modèle multinomial

Modèle logit multinomial (multinomial logit model) : modèle logistique pour une variable dépendante qualitative à $k > 2$ catégories. Si $k = 2$, on retrouve exactement le modèle logit binaire de la Session 6.

- On note $A_1, A_2, \dots, A_k$ les k catégories de la variable dépendante, et $p_1, p_2, \dots, p_k$ les probabilités correspondantes (avec $\sum p_i = 1$).
- Le modèle se formule avec $k-1$ équations, qui expriment la cote conditionnelle (conditional odds) de $k-1$ des k catégories en fonction des variables explicatives.

2. Équations théoriques du modèle

- On choisit l'une des k catégories comme **catégorie de référence** (reference category), par exemple A_1 .
- Les équations expriment le log-odds (conditionnel) de $A_2, A_3, \dots, A_k$ **par rapport à A_1** :

$$\log(p_2/p_1) = \beta_{02} + \beta_{12}x_1 + \dots + \beta_{p2}x_p$$

...

$$\log(p_k/p_1) = \beta_{0k} + \beta_{1k}x_1 + \dots + \beta_{pk}x_p$$

Ce que cette structure dit, étape par étape :

- Il y a une équation séparée pour chaque catégorie non-référence (A_2 à A_k), chacune avec son propre jeu de coefficients β .
- Les coefficients d'une même variable sont en général **différents** d'une équation à l'autre ($\beta_{12} \neq \beta_{13}$ en général).
- Ces log-odds sont dits **conditionnels** car ils ne portent que sur deux événements à la fois, A_i et la catégorie de référence A_1 — dans cette vision "conditionnelle", A_i et A_1 sont traités comme complémentaires, et le ratio

p_i/p_1 représente une cote (odds) ordinaire.

- Comme en régression linéaire et en logit binaire, le membre de droite de chaque équation peut inclure des variables quantitatives, des variables dichotomiques, des interactions et des transformations.

3. Estimation des paramètres

- Les estimations des paramètres $\beta_{0i}, \beta_{1i}, \dots, \beta_{pi}$, pour $i = 2, 3, \dots, k$, sont obtenues par maximum de vraisemblance (maximum likelihood), fournies par R. On les note $b_{0i}, b_{1i}, \dots, b_{pi}$.
- Les équations estimées du modèle sont donc :

$$\log(\hat{p}_2/\hat{p}_1) = b_{02} + b_{12}x_1 + \dots + b_{p2}x_p$$

...

$$\log(\hat{p}_k/\hat{p}_1) = b_{0k} + b_{1k}x_1 + \dots + b_{pk}x_p$$

4. Interpréter un coefficient, cas d'une variable quantitative

- Soit x_1 une variable quantitative ; concentrons-nous sur la première équation (A_2 vs A_1).
- L'estimation b_{12} , effet de x_1 sur la cote de A_2 vs A_1 , indique comment le log-odds estimé de A_2 par rapport à A_1 change quand x_1 augmente d'une unité, les autres variables maintenues constantes.
- Autrement dit, toutes choses égales par ailleurs, une hausse d'une unité de x_1 est associée à un changement en pourcentage de la cote de A_2 vs A_1 égal à :

$$(e^{b_{12}} - 1) \times 100\%$$

- Si $b_{12} > 0$, la cote estimée augmente. Si $b_{12} < 0$, la cote estimée diminue.
- Exactement la même logique s'applique à n'importe quelle autre équation (par exemple b_{13} pour A_3 vs A_1).

5. Interpréter un coefficient, cas d'une variable dichotomique

- Soit x_2 une variable dichotomique (dummy) ; toujours sur la première équation (A_2 vs A_1).
- L'estimation b_{22} , effet de x_2 sur la cote de A_2 vs A_1 , indique comment le log-odds estimé de A_2 par rapport à A_1 change quand x_2 passe de la catégorie codée 0 à la catégorie codée 1, les autres variables maintenues constantes.
- Le changement en pourcentage de la cote de A_2 vs A_1 , quand $x_2 = 1$ comparé à $x_2 = 0$, toutes les autres variables étant fixées, est donné par :

$$(e^{b_{22}} - 1) \times 100\%$$

- Si $b_{22} > 0$, la cote estimée est plus élevée quand $x_2 = 1$. Si $b_{22} < 0$, la cote estimée est plus faible quand $x_2 = 1$.

6. Test sur un coefficient individuel

Test sur un coefficient individuel (modèle multinomial) : $H_0 : \beta_{ji} = 0$ contre $H_1 : \beta_{ji} \neq 0$. Rejeter H_0 signifie conclure (avec une marge d'erreur donnée par le niveau de signification du test) que x_j a un effet sur la cote conditionnelle de A_i par rapport à A_1 dans la population.

- Comme en Session 6, le test repose sur une statistique donnée par le ratio entre le coefficient estimé et son erreur standard, qui suit approximativement une loi normale standard sous H_0 :

$$z_{oss} = b_{ji} / SE(b_{ji})$$

- On rejette H_0 au niveau α (et on conclut à un effet) si $|z_{oss}| > z_{\alpha/2}$, ou de façon équivalente si $p\text{-value} = 2 \cdot P(Z > |z_{oss}|) < \alpha$.

Attention : il est aussi possible de tester des groupes de coefficients ou l'ensemble des coefficients du modèle multinomial, avec des statistiques suivant une loi du chi-carré (comme en Session 7) — mais les slides précisent explicitement que ces tests ne sont pas couverts dans ce cours ("we will not cover them here"). Ne pas chercher à les calculer pour l'examen.

7. Prédiction des probabilités

- Comme toujours, les prédictions s'obtiennent en substituant les valeurs des variables explicatives dans les équations estimées, pour les conditions sous lesquelles on veut prédire.
- Cette substitution donne $k-1$ équations dans les k inconnues $\hat{p}_i$, qui, combinées à la contrainte $\sum \hat{p}_i = 1$, permettent d'obtenir les estimations des probabilités souhaitées.

Ce que cela signifie, étape par étape (méthode générale) :

- Substituer les valeurs fixées des x dans chacune des $k-1$ équations de log-odds → obtenir $k-1$ valeurs numériques.
- Prendre l'exponentielle de chaque équation → obtenir $k-1$ ratios $\hat{p}_i/\hat{p}_1$.
- Résoudre le système linéaire formé par ces $k-1$ ratios et par la contrainte $\hat{p}_1 + \hat{p}_2 + \dots + \hat{p}_k = 1$, pour obtenir chaque $\hat{p}_i$ individuellement.
- En pratique, R effectue directement ce calcul (fonction `predict` avec `type="probs"`).

8. Exemple travaillé complet en R

Contexte, exemple marques (slides) : A_1, A_2, A_3 sont trois marques d'un même type de produit. Y = marque préférée par un consommateur donné. x_1 = âge du consommateur. $x_2 = 1$ si le consommateur est un homme, 0 si c'est une femme. A_1 est prise comme catégorie de référence.

Équations estimées :

$$\log(\hat{p}_2/\hat{p}_1) = 1.2 + 0.03x_1 - 0.6x_2$$

$$\log(\hat{p}_3/\hat{p}_1) = 1.1 + 0.01x_1 + 0.4x_2$$

- Effet de x_1 (âge), x_2 fixé : $b_{12} = 0.03$ ($e^{0.03} = 1.0305$) et $b_{13} = 0.01$ ($e^{0.01} = 1.0101$).
- Une année d'âge supplémentaire est associée à une hausse estimée de 3.05% de la cote de préférer la marque A_2 plutôt que A_1 .
- Une année d'âge supplémentaire est associée à une hausse estimée de 1.01% de la cote de préférer la marque A_3 plutôt que A_1 .
- Effet de x_2 (homme/femme), x_1 fixé : $b_{22} = -0.6$ ($e^{-0.6} = 0.5488$) et $b_{23} = 0.4$ ($e^{0.4} = 1.4918$).

- Pour un homme, la cote de préférer A_2 plutôt que A_1 est estimée 45.12% plus basse que pour une femme (puisque $(0.5488-1) \times 100\% \approx -45.12\%$).

Pour un homme, la cote de préférer A_3 plutôt que A_1 est estimée 49.18% plus haute que pour une femme (puisque $(1.4918-1) \times 100\% \approx 49.18\%$).

Prédiction pour une consommatrice de 30 ans ($x_1 = 30, x_2 = 0$) :

- $\log(\hat{p}_2/\hat{p}_1) = 1.2 + 0.03 \times 30 - 0.6 \times 0 = 2.1 \rightarrow \hat{p}_2/\hat{p}_1 = e^{2.1} = 8.1662$
- $\log(\hat{p}_3/\hat{p}_1) = 1.1 + 0.01 \times 30 + 0.4 \times 0 = 1.4 \rightarrow \hat{p}_3/\hat{p}_1 = e^{1.4} = 4.0552$
- En résolvant $\hat{p}_2 = 8.1662\hat{p}_1, \hat{p}_3 = 4.0552\hat{p}_1, \hat{p}_1 + \hat{p}_2 + \hat{p}_3 = 1 \rightarrow \hat{p}_1 = 0.0757, \hat{p}_2 = 0.6175, \hat{p}_3 = 0.3068$.

Deuxième contexte, exemple étudiants (slides, `multinom()` du package `nnet` en R) : 200 étudiants avant leur entrée au lycée, choix entre 3 filières (program) : general (catégorie de référence choisie par R), academic, vocation. Variables explicatives : score (niveau de préparation) et ses (statut socio-économique, low/middle/high, low = référence).

Coefficients estimés (`summary(mod1)`) : équation academic vs general $\rightarrow$ score = 0.0579, sesmiddle = 0.5333, seshigh = 1.1628 ; équation vocation vs general $\rightarrow$ score = -0.0557, sesmiddle = 0.8246, seshigh = 0.1802.

- Interprétation de score (académic vs general) : $e^{0.0579} = 1.0596 \rightarrow$ toutes choses égales, une hausse d'un point de score est associée à une hausse estimée de 5.96% de la cote de choisir academic plutôt que general.
- Interprétation de seshigh (vocation vs general) : $e^{0.1802} = 1.1975 \rightarrow$ à score égal, la cote de choisir vocation plutôt que general est estimée 19.75% plus élevée pour un statut socio-économique élevé (high) que pour un statut bas (low, référence).
- Tests individuels (z-value = estimation/erreur standard, p-values via pnorm) : score est significatif au seuil 0.05 dans les deux équations ; au seuil 0.05, seul seshigh est significatif dans l'équation academic vs general.
- Prédiction pour un étudiant avec score = 50 et ses = middle (`predict(mod1, ..., type="probs")`) : probabilité general ≈ 0.2334 , academic ≈ 0.4159 , vocation ≈ 0.3507 .

9. Erreurs fréquentes et pièges à l'examen

- Oublier qu'un modèle multinomial à k catégories nécessite k-1 équations, jamais k — la catégorie de référence n'a pas sa propre équation, elle sert de point de comparaison pour toutes les autres.
- Interpréter un coefficient b_{ji} comme un effet sur la probabilité brute p_i , alors qu'il s'agit toujours d'un effet sur la cote **conditionnelle** de A_i par rapport à la catégorie de référence A_1 uniquement.
- Comparer directement deux coefficients de deux équations différentes (par exemple b_{12} et b_{13}) comme s'ils décrivaient le même contraste — chaque équation compare une catégorie différente à la même référence, ce ne sont pas des effets directement comparables entre eux sans précaution.
- Oublier de préciser par rapport à quelle catégorie de référence un coefficient est interprété — l'interprétation n'a de sens que "vs la catégorie de référence".
- Essayer de calculer à la main un test de groupe de coefficients ou du modèle entier pour le modèle multinomial — explicitement hors programme (voir Section 6).

10. À retenir absolument

À retenir :

- Modèle multinomial = k-1 équations de log-odds conditionnels, chaque catégorie non-référence comparée à la catégorie de référence A_1 .

- $\log(p_i/p_1) = \beta_{0i} + \beta_{1i}x_1 + \dots + \beta_{pi}x_p$, coefficients différents pour chaque i , estimés par maximum de vraisemblance.
- Interprétation d'un coefficient b_{ji} : $(e^{b_{ji}} - 1) \times 100\%$ = changement en % de la cote de A_i vs A_1 , toutes les autres variables fixées.
- Test individuel $z_{oss} = b_{ji}/SE(b_{ji})$, même logique que le modèle binaire ; tests de groupe/global explicitement hors programme.
- Prédiction : substituer les x dans les $k-1$ équations $\rightarrow$ exponentielle $\rightarrow$ résoudre le système avec $\sum \hat{p}_i = 1$ (R le fait directement avec ``type="probs"`).

Points de vigilance

Attention : dans l'exemple étudiants, R choisit automatiquement "general" comme référence pour program et "low" comme référence pour ses (l'ordre alphabétique/naturel des catégories) — toujours vérifier explicitement quelle catégorie R a prise comme référence avant d'interpréter les coefficients, plutôt que de le supposer.