

Session 9. Les séries temporelles : caractéristiques générales, transformations et décomposition

À la fin de cette session, vous devez être capable de : définir une série temporelle univariée (univariate time series) et la représenter graphiquement ; citer les objectifs de l'analyse d'une série temporelle et distinguer analyse classique et analyse moderne ; appliquer les transformations usuelles (logarithme, Box-Cox, opérateur backshift B, opérateur différence D) ; calculer une moyenne mobile centrée (centered moving average) d'ordre pair ou impair ; et décomposer une série en tendance (trend), saisonnalité (seasonality) et composante irrégulière (irregular component) selon le modèle multiplicatif ou additif, y compris avec R.

Plan

1. Qu'est-ce qu'une série temporelle
2. Objectifs de l'analyse et deux grandes approches
3. Transformations standard : logarithme et Box-Cox
4. L'opérateur backshift B et l'opérateur différence D
5. Les moyennes mobiles : ordre impair et ordre pair
6. Les trois composantes d'une série temporelle
7. Modèle multiplicatif ou additif
8. La procédure de décomposition en 4 étapes
9. Exemple travaillé complet : les bénéfices trimestriels de Johnson & Johnson
10. Les fonctions R de la session
11. Erreurs fréquentes et pièges à l'examen
12. À retenir absolument

1. Qu'est-ce qu'une série temporelle

Série temporelle univariée (univariate time series) : ensemble de données numériques **ordonnées**, correspondant à une variable relevée à des instants successifs (en général régulièrement espacés).

- On note la série $y_{t_0}, y_{t_0+1}, \dots, y_T$, où t_0 et T sont les instants de début et de fin (souvent on prend $t_0 = 0$ ou $t_0 = 1$), et y_t est la valeur de la variable au temps t .
- Exemples typiques donnés en cours :
 - en macroéconomie : le PIB d'un pays mesuré annuellement ;
 - en démographie : la population d'un pays mesurée annuellement ;
 - en finance : le rendement d'un fonds relevé mensuellement ; le cours de clôture d'une action, un taux de change ou un indice boursier relevés quotidiennement.
- L'exemple fil rouge du début de la session : les cours de clôture quotidiens de l'action Apple Inc, du 3 janvier 2007 au 14 juin 2024 (source Yahoo Finance).

Pour représenter graphiquement une série temporelle :

- En abscisse : les instants auxquels la variable est mesurée ; en ordonnée : les valeurs de la variable.
- On relie les points par des segments : la forme de la courbe fait apparaître visuellement la tendance, les oscillations et les ruptures.

2. Objectifs de l'analyse et deux grandes approches

Les objectifs principaux de l'analyse d'une série temporelle :

- Étudier l'évolution du phénomène dans le temps, en particulier la **tendance de long terme** (long-term trend) et les éventuelles **fluctuations saisonnières** (seasonal fluctuations).
- Étudier la **persistance** : combien de temps les effets d'un choc se font sentir.
- **Prédire** les valeurs futures de la série.

Il existe deux grandes familles de méthodes :

Analyse classique : procédures essentiellement descriptives qui cherchent à identifier les caractéristiques principales de la série (tendance, saisonnalité, irrégularité).

Analyse moderne : modèles probabilistes (processus stochastiques, stochastic processes) qui gouvernent l'évolution du phénomène ; les modèles sont ajustés aux données par des procédures statistiques appropriées.

- Cette session (et la procédure de décomposition) relève de l'analyse **classique**. Les transformations de la section suivante sont nécessaires pour **les deux** approches.

3. Transformations standard : logarithme et Box-Cox

- Transformation logarithmique : $y_t \rightarrow f(y_t) = \log(y_t)$.
- Utile (quand elle est applicable, c'est-à-dire pour des valeurs strictement positives) pour :
- homogénéiser la variabilité (stabiliser la variance) ;
- normaliser la variable ;
- rapprocher une série de la stationnarité (stationarity).

Transformation de Box-Cox : généralisation de la transformation logarithmique, avec un paramètre λ : $f_\lambda(y_t) = \log(y_t)$ si $\lambda = 0$, et $f_\lambda(y_t) = (y_t^\lambda - 1) / \lambda$ si $\lambda \neq 0$.

- Le cas $\lambda = 0$ redonne exactement le logarithme (continuité de la formule quand $\lambda \rightarrow 0$).
- Le choix de λ pilote la force de la transformation : $\lambda = 1$ ne change rien (à une constante près), $\lambda = 0,5$ ressemble à une racine carrée.

4. L'opérateur backshift B et l'opérateur différence D

Opérateur backshift (backshift operator) B : décale la série d'un pas vers le passé : $B y_t = y_{t-1}$.

- On peut l'appliquer plusieurs fois : $B^2 y_t = B(B y_t) = B(y_{t-1}) = y_{t-2}$.
- Par convention $B^0 = 1$: il transforme chaque valeur en elle-même, $B^0(y_t) = y_t$.

Watch out : dans R (package de base), l'opérateur lag décale la série vers l'**avant** : $\text{lag}(y_t) = \text{lag}(y_t, 1) = y_{t+1}$ et $\text{lag}(y_t, k) = y_{t+k}$. Pour obtenir l'équivalent du backshift il faut $\text{lag}(y_t, -1) = y_{t-1} = B y_t$. Le sens est contre-intuitif : retenez que lag avec un argument négatif correspond à B.

Opérateur différence (difference operator) D : $D y_t = y_t - y_{t-1} = y_t - B y_t = (1 - B)y_t$.

- Dans R (package de base), la fonction `diff` calcule la différence entre la valeur courante et une valeur passée : $\text{diff}(y_t) = \text{diff}(y_t, 1) = y_t - y_{t-1}$, et $\text{diff}(y_t, k) = y_t - y_{t-k}$.
- Différencier une série supprime une tendance linéaire : c'est l'outil de base pour rendre une série stationnaire.

5. Les moyennes mobiles : ordre impair et ordre pair

Moyenne mobile centrée d'ordre impair k (centered moving average of odd order) : à chaque temps t , on calcule la moyenne des k valeurs autour de t : $(k-1)/2$ avant t , la valeur en t , et $(k-1)/2$ après t . Le résultat est positionné en t .

Exemple (k = 3) : série 2, 6, 4, 5, 9, 7, 11. La moyenne mobile donne : $(2+6+4)/3 = 4$, puis $(6+4+5)/3 = 5$, puis 6, 7, 9. La nouvelle série perd la première et la dernière valeur : avec k impair, on perd $(k-1)/2$ valeurs au début et autant à la fin.

Moyenne mobile centrée d'ordre pair k : à chaque temps t , on calcule une moyenne pondérée des $k+1$ valeurs autour de t : $k/2$ avant, la valeur en t , $k/2$ après. La première et la dernière valeur ont un poids $1/(2k)$, les autres un poids $1/k$. On perd $k/2$ valeurs au début et $k/2$ à la fin.

Exemple (k = 4) : série 2, 6, 4, 5, 9, 7, 11. Première valeur : $(2 + 2 \cdot 6 + 2 \cdot 4 + 2 \cdot 5 + 9)/8 = 5,125$; puis $(6 + 2 \cdot 4 + 2 \cdot 5 + 2 \cdot 9 + 7)/8 = 6,125$; puis $(4 + 2 \cdot 5 + 2 \cdot 9 + 2 \cdot 7 + 11)/8 = 7,125$. On perd les deux premières et les deux dernières valeurs.

Ce qu'il faut comprendre sur le calcul, étape par étape (cas k pair) :

- On prend $k+1$ valeurs centrées en t (et non k) : c'est ce qui permet de recentrer exactement sur t malgré l'ordre pair.
- Les deux valeurs extrêmes reçoivent un poids moitié ($1/(2k)$) : au total, les poids somment à 1, comme pour une moyenne ordinaire.
- En R : la fonction `ma` (package `forecast`) calcule la moyenne mobile de n'importe quel ordre : `m4 <- ma(y, 4)`.

Effet d'une moyenne mobile sur la série :

- Effet **lissant** (smoothing effect) : elle réduit les fluctuations, puisqu'elle repose sur des moyennes. Plus l'ordre k est grand, plus le lissage est prononcé.
- Une moyenne mobile d'ordre k **réduit ou élimine les oscillations périodiques régulières de période k**. Par exemple, avec des données trimestrielles (périodicité 4), une moyenne mobile d'ordre 4 élimine les oscillations saisonnières, car chaque valeur est une moyenne sur les 4 trimestres avec le même poids pour chaque trimestre.
- C'est exactement cette propriété qui est exploitée à l'étape 1 de la décomposition.

6. Les trois composantes d'une série temporelle

L'objectif de la décomposition (decomposition) est d'identifier les composantes typiques d'une série (même si elles ne sont pas toujours toutes présentes) :

Tendance ou trend-cycle (trend) : le comportement de moyen-long terme de la série (par exemple croissant ou décroissant).

Saisonnalité (seasonality) : variations de périodicité constante, en général dues à des facteurs saisonniers (mensuels, trimestriels...).

Erreur ou composante irrégulière (error / irregular component) : tout ce qui influence la série sans entrer dans les deux composantes précédentes : fluctuations aléatoires sans périodicité régulière ni tendance définie.

- Parfois on distingue la vraie tendance (long terme) de la composante cyclique (cycle) : variations de périodicité **irrégulière**, en général de moyen terme, souvent liées aux cycles économiques (récessions, reprises). En pratique on les regroupe en une seule composante trend-cycle, comme dans cette session.
- La saisonnalité est typique des séries de ventes ou de fourniture de biens et services (ventes de boissons ou de glaces, fourniture de gaz ou d'électricité, services touristiques). Avec des données **annuelles**, la composante saisonnière est en général absente.

7. Modèle multiplicatif ou additif

Deux hypothèses possibles sur la manière dont les composantes T, S et E se combinent :

Modèle multiplicatif : $y_t = T_t \cdot S_t \cdot E_t$

Modèle additif : $y_t = T_t + S_t + E_t$

Ce choix change tout, en pratique :

- Dans le modèle **multiplicatif**, les fluctuations saisonnières ont une amplitude qui dépend du **niveau** de la série : si la tendance est croissante, les oscillations grandissent avec le temps. Les indices saisonniers fluctuent autour de **1**.
- Dans le modèle **additif**, l'amplitude des fluctuations est constante quel que soit le niveau. Les indices saisonniers fluctuent autour de **0**.
- On passe de l'un à l'autre par une transformation logarithmique (quand elle est applicable) : $\log(y_t) = \log(T_t) + \log(S_t) + \log(E_t)$.
- Sans composante saisonnière, les modèles se réduisent à une combinaison de tendance et de composante irrégulière.

8. La procédure de décomposition en 4 étapes

Procédure classique (fondée sur les moyennes mobiles), présentée pour le modèle multiplicatif :

- **Étape 1.** Calculer la moyenne mobile d'ordre égal à la période saisonnière k , notée M_t^k . But : supprimer la saisonnalité tout en réduisant la composante irrégulière (effet lissant). Il reste la tendance : $M_t^k \cong T_t$.
- **Étape 2.** Diviser la série originale par la moyenne mobile : $y_t / M_t^k \cong (T_t \cdot S_t \cdot E_t) / T_t = S_t \cdot E_t$. Ce ratio estime le produit saisonnalité $\times$ irrégulier.
- **Étape 3.** Pour chaque période (mois, trimestre...), calculer la moyenne arithmétique simple des valeurs y_t / M_t^k , puis renormaliser ces moyennes pour que leur moyenne vaille 1. Cela élimine la composante erratique du produit $S_t \cdot E_t$ et isole la saisonnalité. Les valeurs obtenues, identiques

pour chaque période ($S_{t+k} = S_t$), sont les **indices saisonniers** (seasonal indices), qui fluctuent autour de 1.

- **Étape 4.** Diviser le ratio $y_t/M_t^k \cong S_t \cdot E_t$ par S_t : il reste la composante irrégulière E_t , qui doit avoir un comportement aléatoire, sans tendance, avec des fluctuations de périodicité non constante autour de 1.

Watch out : pour le modèle **additif**, les étapes sont les mêmes mais les **divisions deviennent des soustractions**. Les indices saisonniers fluctuent autour de **0** (et non 1), et la composante irrégulière finale doit être aléatoire autour de 0 (et non 1). À l'examen, vérifiez toujours quel modèle est demandé avant de diviser ou soustraire.

9. Exemple travaillé complet : les bénéfices trimestriels de Johnson & Johnson

Données : EPS (earnings per share, bénéfice par action, en dollars) de Johnson & Johnson, relevés trimestriellement sur 20 ans. Le graphe montre une tendance clairement croissante, des oscillations régulières (baisses marquées au 4^e trimestre de chaque année) et des variations irrégulières.

Étape 1. Moyenne mobile d'ordre 4 (données trimestrielles). Premières valeurs : 1960 Qtr1 = 0,71 ; Qtr2 = 0,63 ; Qtr3 = 0,85 ; Qtr4 = 0,44 ; 1961 Qtr1 = 0,61. Première valeur de la moyenne mobile : $(1/8) \cdot 0,71 + (1/4) \cdot 0,63 + (1/4) \cdot 0,85 + (1/4) \cdot 0,44 + (1/8) \cdot 0,61 = 0,645$, positionnée au 3^e trimestre 1960 (les deux premières valeurs sont NA). En R : `M4 <- ma(JJ, 4)`.

Étape 2. `SE <- JJ/M4`. Premières valeurs de SE : 1960 Qtr3 = 1,3178 ; Qtr4 = 0,6875 ; 1961 Qtr1 = 0,9295 ; etc. Cette série estime $S_t \cdot E_t$.

Étape 3. Moyennes de SE par trimestre : 0,9926 (Qtr1) ; 1,0326 (Qtr2) ; 1,1136 (Qtr3) ; 0,8596 (Qtr4). Leur moyenne vaut 0,9996 ; on renormalise en divisant chacune par 0,9996. Indices saisonniers finaux : Qtr1 = 0,993 ; Qtr2 = 1,033 ; Qtr3 = 1,114 ; Qtr4 = 0,860.

Lecture des indices saisonniers :

- Leur moyenne vaut 1 par construction. Une valeur > 1 indique un effet positif pour la période, < 1 un effet négatif.
- Ici : hausse maximale au 3^e trimestre (environ +11 % par rapport à la moyenne annuelle), baisse maximale au 4^e trimestre (environ -14 %).

Étape 4. On divise chaque valeur de SE par l'indice saisonnier de son trimestre : il reste la composante irrégulière. Son graphe montre un comportement adapté : pas de tendance particulière, fluctuations pas trop régulières autour de 1 → la décomposition est cohérente.

10. Les fonctions R de la session

- `ma(y, k)` (package forecast) : moyenne mobile d'ordre k (pair ou impair). Ex. : `m4 <- ma(JJ, 4)`.
- `decompose(y, type = "mult")` (package de base) : réalise toute la décomposition selon la procédure décrite ; l'option type choisit le modèle ("mult" pour multiplicatif ; le défaut est l'additif).
- L'objet retourné contient les composantes, accessibles directement :

- `dec_m$trend` : la série de tendance ;
- `dec_m$figure` : les indices saisonniers (pour J&J : 0,9930 ; 1,0330 ; 1,1141 ; 0,8600) ;
- `dec_m$random` : la composante irrégulière.
- `plot(dec_m)` trace les graphes des différentes composantes.
- Rappels utiles : `lag(y, k)` décale vers l'avant (attention au sens, voir section 4) ; `diff(y, k)` calcule $y_t - y_{t-k}$.

11. Erreurs fréquentes et pièges à l'examen

- Confondre le sens de lag en R : `lag(y)` avance la série (y_{t+1}) alors que B recule (y_{t-1}) ; il faut `lag(y, -1)` pour obtenir B y.
- Oublier les valeurs perdues aux extrémités : $(k-1)/2$ de chaque côté pour k impair, $k/2$ de chaque côté pour k pair.
- Pour un k pair, oublier la pondération : les deux valeurs extrêmes pèsent $1/(2k)$, les autres $1/k$, et on moyenne $k+1$ valeurs (pas k).
- Oublier la renormalisation de l'étape 3 : les moyennes par période doivent être divisées par leur propre moyenne pour que les indices saisonniers aient une moyenne de 1.
- Appliquer les divisions du modèle multiplicatif quand l'énoncé demande l'additif : dans l'additif on soustrait, les indices tournent autour de 0 et l'irrégulier autour de 0.
- Interpréter un indice saisonnier de 1,114 comme « +114 % » : c'est +11,4 % par rapport à la moyenne.
- Conclure que la décomposition a échoué si l'irrégulier n'est pas parfaitement aléatoire : on cherche seulement l'absence de tendance et de périodicité régulière.
- Chercher une saisonnalité dans des données annuelles : elle est en général absente par construction.

12. À retenir absolument

Must know :

- Série temporelle univariée = données ordonnées dans le temps ; graphe = temps en abscisse, valeurs en ordonnée.
- Objectifs : tendance long terme, saisonnalité, persistance, prédiction. Analyse classique = descriptive ; analyse moderne = processus stochastiques.
- $B y_t = y_{t-1}$; $D y_t = (1-B)y_t = y_t - y_{t-1}$; Box-Cox généralise le log (cas $\lambda = 0$).
- Moyenne mobile d'ordre k : lissage + suppression des oscillations de période k ; k pair → poids $1/(2k)$ aux extrêmes, $k+1$ valeurs.
- Composantes : tendance (trend-cycle), saisonnalité (périodicité constante), irrégulier (le reste).
- Multiplicatif : $y = T \cdot S \cdot E$, indices autour de 1, divisions ; additif : $y = T + S + E$, indices autour de 0, soustractions.
- Décomposition en 4 étapes : $M^k \rightarrow y/M^k \rightarrow$ moyennes par période renormalisées (= indices saisonniers) → division par les indices (= irrégulier).
- En R : `ma(y, k)` puis `decompose(y, type = "mult")` ; `dec_m$trend`, `dec_m$figure`, `dec_m$random`.

Watch Out

Watch out : le sens de lag dans R est l'inverse du backshift B : $\text{lag}(y, 1) = y_{t+1}$, il faut $\text{lag}(y, -1)$ pour obtenir $B y = y_{t-1}$.

Watch out : en modèle additif, remplacer toutes les divisions par des soustractions ; indices saisonniers et composante irrégulière centrés sur 0, pas sur 1.

Watch out : les graphes des slides (série Apple, série Johnson & Johnson et ses composantes) ne sont pas reproduits ici : reprenez le PDF du cours pour l'allure visuelle des séries et des décompositions.