

Session 11. Modèles AR, MA, ARMA et ARIMA : sélection, estimation et diagnostic

À la fin de cette session, vous devez être capable de : définir un modèle autorégressif AR(p) et donner les propriétés du AR(1) stationnaire (moyenne, variance, autocorrélations) ; définir un modèle moyenne mobile MA(q) et ses propriétés ; distinguer les signatures ACF/PACF des modèles AR et MA ; définir les modèles ARMA(p,q) et ARIMA(p,d,q) et retrouver les cas particuliers ; dérouler la démarche de sélection d'un modèle ARIMA (identification de d, choix de p et q, estimation par maximum de vraisemblance, analyse des résidus) ; et utiliser les tests de Dickey-Fuller augmenté (ADF) et de Ljung-Box ainsi que les fonctions R arima et auto.arima.

Plan

1. Modèles autorégressifs AR(p) et le cas AR(1)
2. Signatures ACF/PACF d'un AR
3. Modèles moyenne mobile MA(q)
4. Signatures ACF/PACF d'un MA
5. Modèles mixtes ARMA(p,q)
6. Modèles intégrés ARIMA(p,d,q) et cas particuliers
7. La démarche de sélection d'un modèle ARIMA
8. Les fonctions R : arima et auto.arima
9. Exemple : l'ETF Invesco QQQ
10. Tests de stationnarité (ADF) et de Ljung-Box
11. Erreurs fréquentes et pièges à l'examen
12. À retenir absolument

1. Modèles autorégressifs AR(p) et le cas AR(1)

- La marche aléatoire et la marche aléatoire avec dérive peuvent être vues comme des modèles de régression (simples) où la variable explicative est la variable expliquée décalée d'un pas. On généralise en considérant plusieurs décalages.

Modèle autorégressif d'ordre $p \geq 1$, AR(p) : processus $(Y_t)_{t \in T}$ gouverné par $Y_t = \varphi_0 + \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + \dots + \varphi_p Y_{t-p} + \varepsilon_t$, où $\varphi_0, \varphi_1, \dots, \varphi_p$ sont des paramètres et ε_t un bruit blanc.

Cas particulier central : le AR(1), $Y_t = \varphi_0 + \varphi_1 Y_{t-1} + \varepsilon_t$.

- Si $\varphi_0 = 0$ et $\varphi_1 = 1 \rightarrow$ marche aléatoire ; si $\varphi_0 \neq 0$ et $\varphi_1 = 1 \rightarrow$ marche aléatoire avec dérive.
- Le processus est **stationnaire si et seulement si $\varphi_1 \in (-1, 1)$** . Dans ce cas :

$$\begin{aligned}\mu_t &= E[Y_t] = \varphi_0 / (1 - \varphi_1) \\ \sigma_t^2 &= \text{Var}[Y_t] = \sigma^2 / (1 - \varphi_1^2) \\ \rho_{k,t} &= \text{Corr}[Y_t, Y_{t-k}] = \varphi_1^k\end{aligned}$$

Remarques sur le AR(1) stationnaire :

- L'autocorrélation φ_1^k , puisque $|\varphi_1| < 1$, **décroît** quand le lag k augmente. Si $\varphi_1 > 0$, toutes les autocorrélations restent positives ; si $\varphi_1 < 0$, elles alternent entre valeurs positives et négatives.
- L'ACF décrit la persistance : si $|\varphi_1|$ est petit, l'effet d'un choc au temps t se réduit vite dans les périodes suivantes.
- La PACF tend à être négligeable, sauf l'autocorrélation partielle d'ordre 1 (égale à φ_1).

Les trois autocorrélogrammes du cours (AR(1) stationnaires) :

- $\phi_1 = 0,9$: autocorrélations 0,9 ; 0,81 ; 0,729 ; ... ; $0,9^k \rightarrow$ forte persistance.
- $\phi_1 = 0,1$: autocorrélations 0,1 ; 0,01 ; 0,001 ; ... ; $0,1^k \rightarrow$ persistance très faible.
- $\phi_1 = -0,5$: autocorrélations $-0,5$; 0,25 ; $-0,125$; ... ; $(-0,5)^k \rightarrow$ oscillations positives/négatives, décroissant en valeur absolue jusqu'à devenir négligeables.

Pour un AR(p) avec $p > 1$, les fonctions (moyenne, variance, autocorrélations) deviennent plus complexes et ne sont pas données ; on retient seulement les signatures ACF/PACF ci-dessous.

2. Signatures ACF/PACF d'un AR

Pour un AR(p) :

- L'**ACF** décroît en général (de manière exponentielle ou avec un motif sinusoïdal).
- La **PACF** montre typiquement un **dernier pic non négligeable à l'ordre p**.

3. Modèles moyenne mobile MA(q)

Modèle moyenne mobile d'ordre q, MA(q) : $Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} = \sum_{i=0}^q \theta_i \varepsilon_{t-i}$, où ε_t est un bruit blanc, θ_i ($i = 1, \dots, q$) des paramètres et $\theta_0 = 1$. On peut ajouter une constante c à l'équation.

- Y_t est donc une moyenne **pondérée** des ε_t (au temps courant et passés) : d'où le nom « moyenne mobile ». Ne pas confondre avec la moyenne mobile de la session 9 (outil de lissage) : ici c'est un modèle probabiliste.
- Un MA(q) est **stationnaire quels que soient les coefficients et l'ordre q**. De plus :

$$\begin{aligned}\mu_t &= E[Y_t] = 0 \\ \sigma_t^2 &= \text{Var}[Y_t] = (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2) \sigma^2 = \sigma^2 \sum_{i=0}^q \theta_i^2 \\ \rho_{k,t} &= (\sum_{i=0}^q \theta_i \theta_{i-k}) / (\sum_{i=0}^q \theta_i^2) \text{ (avec } \theta_j = 0 \text{ pour } j < 0) \\ &\rightarrow \text{les autocorrélations sont nulles pour } k > q\end{aligned}$$

Remarques sur le MA :

- Comme pour les AR, les propriétés (en particulier la persistance) dépendent de l'ordre et des coefficients. La persistance augmente avec l'ordre q , puisque les autocorrélations d'ordre $> q$ sont nulles.
- Pour un MA(1) : $\rho_1 = \theta_1 / (1 + \theta_1^2)$ est la seule autocorrélation non nulle. La persistance est d'autant plus forte que $|\theta_1|$ est proche de 1. Pour $\theta_1 = 0$, le processus se réduit à un bruit blanc (persistance nulle) ; pour $\theta_1 = 1$, ρ_1 atteint son maximum (0,5) ; pour $\theta_1 = -1$, son minimum ($-0,5$).
- La variance (donc la dispersion) augmente avec la valeur absolue de θ_1 .
- Exemples du cours : séries et autocorrélogrammes de MA(1) avec $\theta_1 = 1$ puis $\theta_1 = 5$.

4. Signatures ACF/PACF d'un MA

Pour un MA(q) :

- L'**ACF** montre typiquement un **dernier pic non négligeable à l'ordre q**.

- La **PACF** tend à décroître (exponentiellement ou avec un motif sinusoïdal).

Moyen mnémotechnique : par rapport à un autorégressif, dans un moyenne mobile les comportements de l'ACF et de la PACF sont **inversés**. AR : ACF décroît, PACF coupe après p. MA : ACF coupe après q, PACF décroît.

5. Modèles mixtes ARMA(p,q)

Modèle ARMA(p,q) (AutoRegressive Moving Average) : modèle avec une composante autorégressive d'ordre p et une composante moyenne mobile d'ordre q : $Y_t = \varphi_0 + \varphi_1 Y_{t-1} + \dots + \varphi_p Y_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t$, où ε_t est un bruit blanc.

- Grande flexibilité grâce au choix des ordres p et q et des coefficients ; pas nécessairement stationnaire, à cause de la composante autorégressive.

6. Modèles intégrés ARIMA(p,d,q) et cas particuliers

Modèle ARIMA(p,d,q) (autoregressive integrated moving average) : généralisation des ARMA. Le « I » désigne une opération d'**intégration**, inverse de la différentiation : la classe inclut les processus auxquels l'opérateur différence D a été appliqué (éventuellement plusieurs fois), en général pour rendre la composante autorégressive stationnaire.

- Par exemple, un ARIMA(3,1,2) correspond à un processus qui, après une différenciation, donne un ARMA(3,2).
- Équation générale : $Y'_t = \varphi_0 + \varphi_1 Y'_{t-1} + \dots + \varphi_p Y'_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t$, où Y'_t est la série différenciée d fois, $Y'_t = D^d(Y_t)$.
- Attention : appliquer l'opérateur différence d fois n'est **pas** une différence d'ordre d ; c'est (pour d = 2) la différence de la différence.

En annulant un ou plusieurs ordres p, d, q, on retrouve les cas particuliers :

- ARIMA(p,0,q) = ARMA(p,q) ; ARIMA(p,0,0) = AR(p) ; ARIMA(0,0,q) = MA(q) ;
- ARIMA(0,0,0) (avec $\varphi_0 = 0$) = bruit blanc ;
- ARIMA(0,1,0) = marche aléatoire (avec dérive si $\varphi_0 \neq 0$).

7. La démarche de sélection d'un modèle ARIMA

Objectif : trouver le modèle ARIMA qui ajuste le mieux la série donnée.

- **Première étape : identification de l'ordre de différenciation d** (le but est de rendre la série stationnaire). Pas de règle universelle ni de critère absolu : on analyse le graphe de la série (tendance ?) et on mène des tests. En règle générale, on évite les valeurs de d supérieures à 2.
- **Deuxième étape : détermination des ordres p et q.** L'analyse de l'ACF et de la PACF est utile : un (dernier) pic à l'ordre p dans la PACF suggère la valeur p pour la partie autorégressive ; un (dernier) pic à l'ordre q dans l'ACF suggère la valeur q pour la partie moyenne mobile. Ce sont des indications générales, car les deux composantes se chevauchent et s'influencent mutuellement. Il existe aussi des critères statistiques pour déterminer les ordres « optimaux », notamment la **minimisation de l'AIC (Akaike Information Criterion)**, avec un sens analogue à celui des modèles de régression.

- **Troisième étape : estimation des paramètres** à partir des données. Plusieurs méthodes existent ; l'**estimation par le maximum de vraisemblance (MLE, Maximum Likelihood Estimation)** est particulièrement courante et c'est la méthode par défaut dans de nombreuses fonctions logicielles (dont les fonctions R ci-dessous).
- **Diagnostic final : analyse des résidus**, analogue à celle des modèles de régression linéaire. Le résidu $e_t = y_t - \hat{y}_t$ est la différence entre la valeur observée et la valeur prédite (estimée) au même instant. Si le modèle ajuste bien, la série des résidus doit ressembler à un **bruit blanc** : moyenne environ nulle, variabilité assez constante, autocorrélations pas excessivement élevées. Le graphe des résidus, leurs autocorrélogrammes et les tests appropriés aident à vérifier ces caractéristiques.

8. Les fonctions R : arima et auto.arima

- `arima(y, order = c(p,d,q))` (package de base) : estime les paramètres du modèle ARIMA avec les trois ordres fixés (méthode au choix, MLE par défaut). L'option `include.mean = TRUE/FALSE` détermine si le terme constant est inclus ; par défaut TRUE, sauf si la série est différenciée.
- `auto.arima(y)` (package forecast) : détermine automatiquement le modèle « optimal » en sélectionnant les ordres et en estimant les paramètres selon un critère au choix (par défaut la minimisation de l'AIC). L'option `lambda = "auto"` applique une transformation de Box-Cox préliminaire si jugée appropriée, avec le paramètre λ choisi automatiquement.
- `arima` et `auto.arima` permettent aussi d'inclure et d'estimer une éventuelle composante saisonnière, ce qui mène aux modèles **SARIMA**.
- `auto.arima` utilise des procédures efficaces de sélection, mais rien ne garantit que le modèle obtenu soit satisfaisant : un contrôle (par exemple par l'analyse des résidus) et une comparaison avec d'autres modèles sont toujours recommandés.

9. Exemple : l'ETF Invesco QQQ

Application de `auto.arima` à la série des cours de clôture quotidiens de l'ETF Invesco QQQ, du 3 janvier 2007 au 7 juin 2024 (source Yahoo Finance), avec l'option `lambda = "auto"` :

Sortie R : Series: y — ARIMA(1,1,0) with drift — Box Cox transformation: lambda = 0,0988.
Coefficients : ar1 = -0,0888 (s.e. 0,0150), drift = 9.10^{-4} (s.e. 3.10^{-4}). $\sigma^2 = 0,0004955$;
log likelihood = 10471,09 ; AIC = -20936,19.

- Lecture : la procédure automatique (avec la transformation) a sélectionné un ARIMA(1,1,0) avec dérive : après une différenciation de la série transformée, un AR(1) avec terme constant a été estimé. La sortie donne aussi la variance estimée du bruit blanc sous-jacent, le logarithme de la vraisemblance maximale et l'AIC.
- Le graphe des résidus (`plot(mod$residuals)`) confirme l'adéquation : la série des résidus semble présenter les caractéristiques d'un bruit blanc. L'autocorrélogramme des résidus confirme une structure de corrélation proche de celle d'un bruit blanc (quelques autocorrélations légèrement non négligeables persistent souvent sans conduire à rejeter le modèle).

10. Tests de stationnarité (ADF) et de Ljung-Box

Tests de Dickey-Fuller et de Dickey-Fuller augmenté (ADF) : vérifient si une série peut raisonnablement être vue comme une réalisation finie d'un processus (faiblement) stationnaire. Hypothèse nulle H_0 : processus **non stationnaire** ; hypothèse alternative H_1 : processus **stationnaire**. Rejeter H_0 fournit une évidence statistique de stationnarité.

- En R : `adf.test(y)`, fonction du package `tseries`.
- Sur les résidus de l'exemple QQQ : `adf.test(mod$residuals)` donne Dickey-Fuller = $-16,122$, $p\text{-value} = 0,01 \rightarrow H_0$ rejetée (au niveau 0,01), donc évidence de stationnarité. (Message d'avertissement classique : la vraie $p\text{-value}$ est plus petite que celle affichée.)

Test de Ljung-Box : teste l'hypothèse nulle selon laquelle toutes les autocorrélations jusqu'à un certain ordre k sont nulles. Utile, lui aussi, pour le diagnostic des résidus.

- En R : `Box.test(x, lag = k, type = "Ljung-Box")`.
- Sur les résidus QQQ : avec $\text{lag} = 3$, $X\text{-squared} = 0,51775$, $p\text{-value} = 0,915 \rightarrow H_0$ non rejetée ; avec $\text{lag} = 10$, $X\text{-squared} = 54,812$, $p\text{-value} = 3,4 \cdot 10^{-8} \rightarrow H_0$ rejetée. Cohérent avec l'autocorrélogramme des résidus, où quelques autocorrélations significatives subsistaient.

11. Erreurs fréquentes et pièges à l'examen

- Inverser les signatures : AR $\rightarrow$ PACF coupe après p (ACF décroît) ; MA $\rightarrow$ ACF coupe après q (PACF décroît). C'est le piège classique de la session.
- Écrire que le AR(1) est stationnaire pour tout ϕ_1 : il faut $|\phi_1| < 1$; $\phi_1 = 1$ donne une marche aléatoire.
- Appliquer la condition de stationnarité du AR(1) au MA(q) : un MA(q) est stationnaire quels que soient ses coefficients.
- Confondre « différencier d fois » et « différence d'ordre d » : $D^2y = D(Dy)$, pas $y_t - y_{t-2}$.
- Conclure « non stationnaire » quand le test ADF ne rejette pas H_0 : H_0 est la non-stationnarité, donc rejeter H_0 = évidence de stationnarité. Le sens est inversé par rapport à la plupart des tests.
- Oublier que le Ljung-Box dépend du lag choisi : le même résidu peut passer à $\text{lag} = 3$ et échouer à $\text{lag} = 10$ (exemple du cours).
- Croire que `auto.arima` garantit un bon modèle : toujours vérifier les résidus et comparer avec d'autres modèles.
- Chercher une moyenne non nulle dans un MA(q) sans constante : $\mu_t = 0$.
- Confondre le MA(q) probabiliste avec la moyenne mobile de lissage de la session 9.

12. À retenir absolument

Must know :

- AR(p) : $Y_t = \phi_0 + \sum \phi_i Y_{t-i} + \varepsilon_t$. AR(1) stationnaire ssi $|\phi_1| < 1$; alors $\mu = \phi_0/(1-\phi_1)$, $\sigma_Y^2 = \sigma^2/(1-\phi_1^2)$, $\rho_k = \phi_1^k$.
- MA(q) : $Y_t = \sum_{i=0}^q \theta_i \varepsilon_{t-i}$ ($\theta_0 = 1$) ; toujours stationnaire ; $\rho_k = 0$ pour $k > q$. MA(1) : $\rho_1 = \theta_1/(1+\theta_1^2) \in [-0,5 ; 0,5]$.
- Signatures : AR $\rightarrow$ ACF décroît + PACF coupe après p ; MA $\rightarrow$ ACF coupe après q + PACF décroît.
- ARMA(p,q) = AR + MA ; ARIMA(p,d,q) = ARMA sur la série différenciée d fois. ARIMA(0,1,0) = marche aléatoire ; ARIMA(0,0,0) = bruit blanc.
- Sélection : 1) choisir d (graphe + tests, $d \leq 2$) ; 2) choisir p, q (pics PACF/ACF, AIC) ; 3) estimer

(MLE) ; 4) diagnostic : résidus $\approx$ bruit blanc.

- R : `arima(y, order = c(p,d,q))` ; `auto.arima(y, lambda = "auto")` ; `adf.test` (H_0 = non stationnaire) ; `Box.test(x, lag, type = "Ljung-Box")` (H_0 = autocorrélations nulles jusqu'au lag k).

Watch Out

Watch out : le test ADF a pour hypothèse nulle la **non-stationnarité** : rejeter H_0 est une bonne nouvelle (évidence de stationnarité). Ne pas inverser la conclusion.

Watch out : ρ_1 d'un MA(1) ne peut jamais dépasser 0,5 en valeur absolue (maximum en $\theta_1 = 1$, minimum $-0,5$ en $\theta_1 = -1$) : si un calcul donne une valeur plus grande, il est faux.

Watch out : les graphes des slides (autocorrélogrammes des AR(1) et MA(1), série QQQ, résidus) ne sont pas reproduits ici : reprenez le PDF du cours pour leur allure visuelle.