

Session 12. La prévision : lissage exponentiel, méthode de Holt-Winters et prévision dans les modèles ARIMA

À la fin de cette session, vous devez être capable de : définir ce qu'est une prévision (forecast) ; citer et limiter les méthodes naïve et de la moyenne simple ; écrire et interpréter le lissage exponentiel simple (SES, simple exponential smoothing) sous ses deux formes équivalentes ; généraliser avec la méthode de Holt (tendance) et de Holt-Winters (tendance + saisonnalité) ; choisir les paramètres par minimisation de l'erreur quadratique moyenne (MSE) ; prévoir à partir d'un modèle ARMA/ARIMA estimé, y compris à plusieurs pas et après différenciation ; et produire prévisions et intervalles de prédiction en R avec HoltWinters, predict et forecast.

Plan

1. Qu'est-ce qu'une prévision
2. Deux méthodes de base : naïve et moyenne simple
3. Le lissage exponentiel simple (SES)
4. SES sous forme d'équations : niveau et prévision
5. La méthode de Holt : ajouter une tendance
6. La méthode de Holt-Winters : ajouter la saisonnalité
7. Le choix des paramètres par MSE
8. Holt-Winters en R et l'exemple AirPassengers
9. La prévision dans les modèles ARMA et ARIMA
10. Exemple travaillé : prévisions ARMA(2,1) et ARIMA(1,1,0)
11. La fonction forecast en R et l'exemple QQQ
12. Erreurs fréquentes et pièges à l'examen
13. À retenir absolument

1. Qu'est-ce qu'une prévision

Prévision (forecast) : une prévision $\hat{y}_{T+1}$ de la valeur y_{T+1} de la série au temps $T+1$, étant données ses valeurs $y_0, y_1, \dots, y_T$ jusqu'au temps T , est simplement une **fonction** de $y_0, y_1, \dots, y_T$.

- Pour que la prévision ait un sens, cette fonction doit être choisie de manière appropriée.
- Le choix dépend de plusieurs facteurs : présence de tendances, saisonnalité éventuelle, modèle utilisé pour représenter la série.
- Une fois une mesure d'erreur de prévision fixée, un objectif possible est de trouver la fonction qui **minimise cette erreur**.

2. Deux méthodes de base : naïve et moyenne simple

Deux méthodes basiques (et en général inefficaces) :

Méthode naïve (naive forecasting) : la prévision de y_{T+1} (et aussi de y_{T+h} pour tout $h \geq 1$) est la dernière valeur observée : $\hat{y}_{T+1} = y_T$.

Méthode de la moyenne simple (simple mean) : la prévision de y_{T+1} (et de y_{T+h} pour tout $h \geq 1$) est la moyenne des observations : $\hat{y}_{T+1} = (1/(T+1)) \sum_{t=0}^T y_t$.

- Les deux méthodes sont des cas particuliers d'une méthode plus générale où la prévision est une **moyenne pondérée** des valeurs observées : dans le premier cas, tous les poids sont nuls sauf le dernier ; dans le second, tous les poids sont égaux.
- On peut donc généraliser en utilisant une moyenne pondérée bien choisie (par exemple en donnant plus de poids aux données les plus récentes) : c'est l'idée du lissage exponentiel.

3. Le lissage exponentiel simple (SES)

Prévision au temps $T+h$, pour tout $h \geq 1$:

$$\hat{y}_{T+h} = \alpha y_T + \alpha(1-\alpha)y_{T-1} + \alpha(1-\alpha)^2 y_{T-2} + \dots \text{ avec } \alpha \in (0, 1]$$

- Pour prévoir la valeur de la série à un instant futur, on utilise une moyenne pondérée des valeurs disponibles, où les poids **décroissent exponentiellement** quand les observations s'éloignent dans le passé.
- La vitesse à laquelle le poids des observations lointaines décroît est gouvernée par le paramètre $\alpha \in (0, 1]$.

Ce qu'il faut retenir sur le SES :

- Plus α est proche de 1, plus la réduction des poids est forte. Dans le cas extrême **$\alpha = 1$, on retrouve la méthode naïve.**
- Quand α approche 0, toutes les valeurs observées tendent à avoir le même poids (on se rapproche de la moyenne simple).
- Cette méthode peut être appropriée quand il n'y a **ni tendance ni composante saisonnière** dans la série, puisque les prévisions à partir de $T+1$ sont toutes identiques.
- En donnant plus de poids aux observations récentes et grâce à un paramètre qui règle l'ampleur de la réduction, les prévisions tiennent compte, dans une certaine mesure, des caractéristiques de persistance de la série.
- Le paramètre α peut être obtenu en minimisant une erreur (par exemple la MSE, section 7).

4. SES sous forme d'équations : niveau et prévision

Présentation différente mais **équivalente** du SES, en deux équations (utile pour introduire les méthodes plus avancées) :

$$l_t = \alpha y_t + (1-\alpha)l_{t-1} \quad (\text{équation de niveau, level equation, } t = 1, \dots, T, \text{ avec } l_0 = y_0)$$
$$\hat{y}_{T+h} = l_T \quad (\text{équation de prévision, forecast equation, } h \geq 1)$$

- L'équation de niveau fournit un lissage de la série fondé sur la dernière valeur observée et le niveau précédent, pondérés selon α .
- L'équation de prévision prend simplement comme prévision le niveau estimé au dernier instant observé.

5. La méthode de Holt : ajouter une tendance

Généralisation du SES pour inclure une éventuelle tendance (linéaire). Trois équations :

$$l_t = \alpha y_t + (1-\alpha)(l_{t-1} + b_{t-1}) \quad (\text{équation de niveau, } t = 1, \dots, T)$$

$$b_t = \beta(l_t - l_{t-1}) + (1-\beta)b_{t-1} \quad (\text{équation de tendance, trend equation, } t = 1, \dots, T)$$

$$\hat{y}_{T+h} = l_T + h \cdot b_T \quad (\text{équation de prévision, } h \geq 1)$$

- En plus du niveau initial l_0 , il faut fixer une valeur initiale b_0 pour la tendance.
- Les paramètres à fixer ou estimer sont deux : α et β .

6. La méthode de Holt-Winters : ajouter la saisonnalité

- Nouvelle généralisation du SES, qui permet d'inclure une éventuelle **composante saisonnière**.
- Quatre équations : niveau, tendance, saisonnalité, prévision. L'équation de prévision s'appuie sur les trois autres.
- Deux variantes : l'une considère l'effet de la composante saisonnière comme **additif**, l'autre comme **multiplicatif**.
- Trois paramètres à fixer (un pour chacune des trois premières équations), plus trois valeurs initiales.

7. Le choix des paramètres par MSE

Critère usuel de sélection des paramètres (un pour le SES, deux pour Holt, trois pour Holt-Winters) : la minimisation de l'erreur quadratique moyenne (MSE, mean squared error) de la prévision :

$$MSE = (1/(T+1)) \sum_{t=0}^T (y_t - \hat{y}_t)^2$$

- C'est la moyenne des carrés des différences entre valeurs observées et valeurs prédites, calculée en appliquant la méthode de prévision à chaque instant observé.
- Ces différences sont appelées **résidus** (residuals) ou erreurs de prévision (forecast errors).

8. Holt-Winters en R et l'exemple AirPassengers

- Fonction `HoltWinters` (package de base) : étant donnée une série, détermine les équations en estimant les paramètres par minimisation de la MSE. On choisit entre méthode multiplicative et additive (l'**additive est le défaut**).
- Utilisation de base (méthode multiplicative) : `HW <- HoltWinters(series, seasonal = "mult")`.
- L'objet `HW` se passe ensuite à la fonction générique `predict` : `predict(HW, 5)` donne les prévisions des cinq prochaines périodes $T+h$, $h = 1, \dots, 5$.
- Pour ajouter des **intervalles de prédiction** : `predict(HW, 5, prediction.interval = TRUE, level = 0.9)`. Les intervalles exigent des hypothèses sur les distributions des quantités en jeu. À niveau de confiance égal, les intervalles pour des prévisions plus lointaines deviennent en général **plus larges** (incertitude, donc variabilité, croissante).

Exemple : AirPassengers. Nombre total mensuel de passagers de vols internationaux, 1949-1960 (série au format `ts` dans le package de base de R). Le graphe montre clairement une

composante saisonnière et une tendance (croissante, approximativement linéaire).

- `plot(AirPassengers)`
- `HW <- HoltWinters(AirPassengers, seasonal = "mult")`
- `predict(HW, 12, prediction.interval = TRUE, level = 0.9)` → prévisions pour 1961 : janvier 447,06 [430,48 ; 463,63] ; juillet 666,59 [641,45 ; 691,74] ; août 657,91 [632,12 ; 683,70] ; etc. On retrouve le profil saisonnier : pic en été, creux en novembre (420,21).

9. La prévision dans les modèles ARMA et ARIMA

Avec des modèles stochastiques (ARMA, ARIMA), les prévisions se font typiquement à partir de l'**équation qui définit le processus**, après estimation des paramètres (par exemple par ML).

Pour un AR(p) : $\hat{y}_{T+1} = \hat{\phi}_0 + \hat{\phi}_1 y_T + \hat{\phi}_2 y_{T-1} + \dots + \hat{\phi}_p y_{T-p+1}$

Remarques :

- Pour la prévision **ponctuelle**, il suffit de substituer les coefficients estimés dans l'équation du modèle.
- Comme les estimations sont sujettes à variabilité, la variabilité globale de la prévision augmente : il faut en tenir compte en passant des estimations aux intervalles de prédiction.
- Si la série est suffisamment longue, la variabilité des estimations est réduite et, en pratique, on peut procéder comme si les coefficients étaient connus.
- Prévision à plusieurs pas : on **itére**. Pour $h = 2$: $\hat{y}_{T+2} = \hat{\phi}_0 + \hat{\phi}_1 \hat{y}_{T+1} + \hat{\phi}_2 y_T + \dots + \hat{\phi}_p y_{T-p+2}$, où $\hat{y}_{T+1}$ est la prévision déjà calculée.

Pour un MA(q) et plus généralement un ARMA(p,q), la procédure est analogue :

- Substituer les paramètres du modèle par leurs estimations.
- Substituer les erreurs ε_t par les **résidus** $e_t = y_t - \hat{y}_t$ aux instants observés, et par **0** aux instants futurs non observés (les erreurs futures sont inconnues, on les suppose nulles).
- Pour toute valeur future de la série présente dans l'équation, substituer la prévision correspondante.

Exemple MA(1), $Y_t = \theta_1 \varepsilon_{t-1} + \varepsilon_t$: $\hat{y}_{T+1} = \theta_1 \hat{\varepsilon}_T + \hat{\varepsilon}_{T+1} = \theta_1 (y_T - \hat{y}_T) + 0 = \theta_1 (y_T - \hat{y}_T)$.

Pour les modèles ARIMA, la procédure est la même, en gardant à l'esprit la différenciation éventuelle : les prévisions sont obtenues pour la **série différenciée**, puis il faut une étape de « dé-différenciation » pour revenir à la série originale.

Les intervalles de prédiction correspondants sont en général déterminés en supposant que le bruit blanc sous-jacent suit une distribution **gaussienne** (normale).

10. Exemple travaillé : prévisions ARMA(2,1) et ARIMA(1,1,0)

ARMA(2,1) d'équation (paramètres déjà estimés) : $y_t = 2,4 + 0,2y_{t-1} + 0,4y_{t-2} - 0,3\varepsilon_{t-1} + \varepsilon_t$. Valeurs observées : $y_t = 5$ et $y_{t-1} = 4$; prévision au temps t (calculée avec les valeurs antérieures) : 4,8.

• $\hat{y}_{t+1} = 2,4 + 0,2 \cdot 5 + 0,4 \cdot 4 - 0,3(5 - 4,8) + 0 = 2,4 + 1 + 1,6 - 0,06 = \mathbf{4,94}$

• $\hat{y}_{t+2} = 2,4 + 0,2 \cdot \hat{y}_{t+1} + 0,4 \cdot y_t - 0,3 \cdot 0 + 0 = 2,4 + 0,988 + 2 = \mathbf{5,388}$

Notez : le résidu $e_t = y_t - \hat{y}_t = 0,2$ est utilisé pour $t+1$; les erreurs futures e_{t+1} , e_{t+2} sont remplacées par 0.

ARIMA(1,1,0) sur une série de longueur $T = 201$, équation estimée : $y_t - y_{t-1} = 0,5108 \cdot (y_{t-1} - y_{t-2}) + \varepsilon_t$, soit $y'_t = 0,5108 \cdot y'_{t-1} + \varepsilon_t$ avec $y'_t = y_t - y_{t-1}$. Dernières valeurs : $y_{201} = 16,9146$ et $y_{200} = 15,9217$.

- Équation écrite au temps 202 : $y'_{202} = 0,5108 \cdot y'_{201} + \varepsilon_{202}$.
- ε_{202} remplacé par 0 ; $y'_{201} = y_{201} - y_{200} = 16,9146 - 15,9217 = 0,9929$.
- $\hat{y}'_{202} = 0,5108 \times 0,9929 = 0,5072$.
- Retour à la série originale : $\hat{y}_{202} = \hat{y}'_{202} + y_{201} = 0,5072 + 16,9146 = \mathbf{17,4218}$.

11. La fonction forecast en R et l'exemple QQQ

- forecast (package forecast) fournit les prévisions pour les modèles ARIMA. Version de base (5 périodes) : `ff <- forecast(model, h = 5)`, où model est le modèle estimé (par arima ou auto.arima).
- L'objet ff contient beaucoup d'informations, en particulier les prévisions demandées avec les intervalles correspondants (à 80 % et 95 %).

Exemple QQQ : `ff <- forecast(mod, 10)` appliqué au modèle ARIMA(1,1,0) obtenu par `auto.arima` sur les cours de clôture quotidiens de l'ETF Invesco QQQ. Sortie : Point Forecast 464,91 ; 465,14 ; 465,37 ; 465,59 ; ... avec colonnes Lo 80 / Hi 80 / Lo 95 / Hi 95 (par exemple pour le 1^{er} jour : [457,73 ; 472,19] à 80 % et [453,97 ; 476,08] à 95 %). La commande `plot(ff, include = 100)` visualise les prévisions et leurs intervalles avec les 100 derniers jours de la série.

12. Erreurs fréquentes et pièges à l'examen

- Utiliser le SES sur une série avec tendance ou saisonnalité : les prévisions sont constantes à partir de $T+1$, elles ne peuvent pas suivre. Prendre Holt (tendance) ou Holt-Winters (tendance + saisonnalité).
- Croire que α proche de 1 lisse davantage : c'est l'inverse, α proche de 1 donne presque tout le poids à la dernière valeur (cas extrême = méthode naïve) ; le lissage est fort quand α est petit.
- Dans une prévision ARMA, remplacer les erreurs futures par le résidu courant : les ε_t futurs inconnus sont remplacés par 0 ; seuls les instants observés utilisent les résidus.
- Oublier l'étape de dé-différenciation pour un ARIMA : la prévision calculée concerne la série différenciée, il faut la ramener à l'échelle originale (exemple : $\hat{y}_{202} = \hat{y}'_{202} + y_{201}$).
- Intervertir additif et multiplicatif dans Holt-Winters : le défaut de la fonction R est l'additif ; pour l'option multiplicative il faut `seasonal = "mult"`.
- Croire que l'intervalle de prédiction reste de largeur constante : il s'élargit avec l'horizon h (incertitude croissante).
- Confondre résidus et erreurs futures : $e_t = y_t - \hat{y}_t$ n'existe qu'aux instants observés.
- Présenter une prévision ponctuelle sans intervalle comme si elle était certaine : les estimations des paramètres ajoutent de la variabilité.

13. À retenir absolument

Must know :

- Prévision = fonction des valeurs passées ; son choix dépend de la tendance, de la saisonnalité et du modèle.

- Naïve : $\hat{y} = y_T$; moyenne simple : $\hat{y} = \text{moyenne des observations}$; les deux sont des moyennes pondérées extrêmes.
- SES : poids $\alpha(1-\alpha)^j$ décroissant exponentiellement ; $\alpha = 1 \rightarrow$ naïve, $\alpha \rightarrow 0 \rightarrow$ moyenne simple ; adapté sans tendance ni saisonnalité ; $\hat{y}_{T+h} = I_T$.
- Holt : ajoute l'équation de tendance b_t ; $\hat{y}_{T+h} = I_T + h \cdot b_T$. Holt-Winters : ajoute l'équation de saisonnalité ; variantes additive et multiplicative.
- Paramètres choisis par minimisation de la MSE = moyenne des carrés des résidus.
- Prévision ARMA : substituer paramètres estimés, résidus aux instants observés, 0 aux instants futurs, prévisions itérées pour les valeurs futures ; ARIMA : prévoir la série différenciée puis dé-différencier ; intervalles sous hypothèse gaussienne.
- R : `HoltWinters(series, seasonal = "mult")` ; `predict(HW, h, prediction.interval = TRUE, level = 0.9)` ; `forecast(model, h)` avec intervalles 80 % et 95 % ; `plot(ff, include = 100)`.

Watch Out

Watch out : les erreurs futures sont toujours remplacées par 0 dans les prévisions ARMA/ARIMA : les remplacer par autre chose (résidu courant, moyenne des résidus) est faux.

Watch out : pour un ARIMA avec $d \geq 1$, la prévision brute concerne la série différenciée : sans l'étape de retour à la série originale (ajouter y_T pour $d = 1$), le résultat est sur la mauvaise échelle.

Watch out : les graphes des slides (AirPassengers et ses prévisions, graphe final QQQ avec intervalles) ne sont pas reproduits ici : reprenez le PDF du cours pour leur allure visuelle.