

Révision des bases — Premier In-Class Test (basé sur le mock quiz de 22 questions, dataset SUPERMARKET)

À la fin de cette fiche, vous devez être capable de : écrire l'équation d'un modèle de régression multiple avec des variables muettes, interpréter correctement chaque type de coefficient, tester la significativité d'une variable seule (test t) ou d'un groupe de variables (test F partiel), construire et lire un intervalle de confiance, juger si une prédiction est raisonnable, comparer deux modèles emboîtés ou non emboîtés, et faire le pont vers les données de panel (effets fixes, test de Hausman) vu en fin de quiz.

Plan

1. Le modèle de régression multiple avec variables muettes
2. Interpréter un coefficient : variable quantitative vs variable muette
3. Tester la significativité d'une seule variable : le test t
4. Intervalles de confiance pour les coefficients et pour une prédiction
5. Prédiction et son caractère "raisonnable"
6. Comparer deux modèles emboîtés : le test F partiel
7. Comparer deux modèles non emboîtés : R^2 ajusté
8. Significativité globale du modèle : test F global, R^2 et R^2 ajusté
9. Passage aux données de panel : effets fixes et test de Hausman
10. Fonctions R à connaître par cœur
11. Erreurs courantes et pièges d'examen
12. À savoir absolument

1. Le modèle de régression multiple avec variables muettes

Exemple fil rouge (dataset SUPERMARKET, dataframe SUP, 150 supermarchés) : CN (nombre de clients quotidien) expliqué par S (surface en m², quantitative), HD (livraison à domicile, "yes"/"no") et AE (facilité d'accès, "low"/"average"/"high").

- **Règle des k-1 muettes.** Pour intégrer une variable qualitative à k catégories dans un modèle, il faut introduire k-1 variables muettes, qui identifient k-1 des k catégories. La catégorie manquante devient la **catégorie de référence** (reference category), automatiquement absorbée dans l'intercept.
- HD a 2 catégories → 1 seule muette : HDyes (référence : "no").
- AE a 3 catégories → 2 muettes : AEaverage, AEhigh (référence : "low").

$$CN = \beta_0 + \beta_S S + \beta_{HDyes} HDyes + \beta_{AEaverage} AEaverage + \beta_{AEhigh} AEhigh + \varepsilon$$

où :

- β_0 est la valeur moyenne de CN pour la catégorie de référence (HD = "no", AE = "low") quand S = 0
- β_S est l'effet marginal de S, toutes les autres variables étant fixées
- β_{HDyes} , $\beta_{AEaverage}$, β_{AEhigh} sont des écarts par rapport à la catégorie de référence, pas des niveaux absolus

Ce que ça calcule concrètement, étape par étape :

- On commence toujours par repérer la catégorie de référence (celle qui n'a pas de muette dans l'équation) — c'est elle qui sert de point de comparaison à toutes les autres.
- Chaque coefficient de muette (β_{HDyes} , $\beta_{AEaverage}$, β_{AEhigh}) se lit comme "la différence moyenne de CN par rapport à la référence, à S et aux autres variables fixés".

- En R, `lm(CN ~ S + HD + AE, data = SUP)` choisit automatiquement les références par ordre alphabétique du facteur ("no" avant "yes", "average"/"high"/"low" → "low" en premier).

Attention : une équation qui garde toutes les catégories d'une variable qualitative en même temps (par exemple HDyes ET HDno, ou les 3 niveaux de AE) est fautive — c'est de la colinéarité parfaite avec l'intercept, la règle k-1 doit toujours être respectée.

2. Interpréter un coefficient : variable quantitative vs variable muette

Sortie R de référence (`mod1 <- lm(CN ~ S + HD + AE, data = SUP)`) :

Intercept 78.5686 • S 1.3578 (se 0.1414) • HDyes 64.1552 (se 67.0423) • AEaverage 3.3731 (se 77.5183) • AEhigh 22.8031 (se 86.0397)

2.1 Variable quantitative (S)

- Une augmentation d'**une unité** de S est associée à une augmentation moyenne de 1.3578 clients, toutes les autres variables étant fixées (à n'importe quel niveau — HD et AE peuvent être fixés à n'importe quelle combinaison, l'effet ne change pas).
- Une augmentation de **c unités** de S est associée à un changement moyen de $c \times 1.3578$ (le modèle est linéaire dans S).
- Le coefficient 1.3578 est l'**estimation**, 0.1414 est son **erreur standard** (standard error) — ne jamais confondre les deux : l'erreur standard sert à construire le test/l'intervalle de confiance, pas à mesurer l'effet lui-même.

2.2 Variable muette (HDyes, AEaverage, AEhigh)

- HDyes = 64.1552 : les supermarchés avec livraison à domicile ont, en moyenne, 64.1552 clients de plus que ceux sans livraison, à S et AE fixés.
- AEaverage = 3.3731 et AEhigh = 22.8031 : écarts par rapport à AE = "low" (la référence), à S et HD fixés.
- Le raisonnement "l'effet d'une variable est le même quels que soient les niveaux fixés des autres" (additivité) s'applique aussi aux muettes tant qu'il n'y a pas de terme d'interaction dans le modèle.

Must know :

- Coefficient d'une quantitative → effet marginal par unité, valable à n'importe quel niveau des autres variables.
- Coefficient d'une muette → écart moyen par rapport à la catégorie de référence, autres variables fixées.
- Ne jamais lire l'erreur standard (std. error) comme si c'était le coefficient.

3. Tester la significativité d'une seule variable : le test t

Test t (t-test) sur un coefficient : teste si une variable explicative a un effet réel sur Y, une fois les autres variables du modèle prises en compte.

$$H_0 : \beta_j = 0 \quad \text{contre} \quad H_1 : \beta_j \neq 0$$

où :

- β_j est le coefficient (population) de la variable testée
- la statistique de test est le **t value** donné par R (colonne "t value" de `summary()`), calculé comme $\text{estimate} / \text{std. error}$

Ce que ça calcule concrètement, étape par étape :

- On lit directement la ligne de la variable dans `summary(mod1)` : par exemple pour S, $t \text{ value} = 9.601 (= 1.3578 / 0.1414)$.
- On compare la p-value (colonne " Pr(>|t|) ") au seuil choisi (souvent 0.05) : $p\text{-value} < \text{seuil} \rightarrow$ on rejette H_0 , la variable est significative.
- Dans `mod1` : seule S est significative au seuil 0.05 ($p\text{-value} < 2e-16$). HDyes ($p = 0.340$), AEaverage ($p = 0.965$) et AEhigh ($p = 0.791$) ne le sont pas individuellement.

Attention : un test t sur une seule muette d'une variable à plusieurs catégories (ex. AEaverage seule) ne dit rien sur la pertinence globale de la variable AE — il faut un test F partiel sur le groupe complet de muettes (Section 6).

4. Intervalles de confiance pour les coefficients et pour une prédiction

```
confint(mod1, level = 0.99)
```

Ce que ça calcule concrètement, étape par étape :

- Donne, pour chaque coefficient, une fourchette de valeurs plausibles pour β_j au niveau de confiance choisi (ici 99%).
- Exemple pour HDyes : $[-110.84 ; 239.15]$ au niveau 99% $\rightarrow$ l'écart moyen de clientèle entre "avec" et "sans" livraison, toutes autres variables fixées, se situe avec 99% de confiance dans cette fourchette (qui contient 0, cohérent avec un test t non significatif).
- **Règle générale à retenir** : plus le niveau de confiance demandé est élevé ($99\% > 95\% > 90\%$), plus l'intervalle est **long**, toutes choses égales par ailleurs.
- **Intervalle pour une moyenne (expected value) vs intervalle pour une observation individuelle (prediction interval)** : au même niveau de confiance, l'intervalle pour la valeur moyenne prédite (mean/expected value) est toujours **plus court** que l'intervalle pour la valeur d'une observation individuelle, parce que ce dernier ajoute la variance de l'erreur individuelle à l'incertitude sur la moyenne.

Must know :

- Confiance $\uparrow \rightarrow$ intervalle plus long (à variables/données fixées).
- Intervalle pour la moyenne toujours $<$ intervalle pour une observation individuelle, au même niveau de confiance.

5. Prédiction et son caractère "raisonnable"

```
predict(mod1, data.frame(S = 500, HD = "yes", AE = "low"))
```

Ce que ça calcule concrètement, étape par étape :

- On remplace chaque variable explicative par la valeur demandée dans l'équation estimée : $78.5686 + 1.3578 \times 500 + 64.1552 \times 1 + 3.3731 \times 0 + 22.8031 \times 0 = \mathbf{821.633}$ clients prédits en moyenne.
- Pour juger si cette prédiction est **raisonnable**, deux conditions à vérifier avec `summary(SUP)` :
 - chaque variable **quantitative** utilisée pour la prédiction (ici S = 500) doit tomber **dans la plage observée** dans l'échantillon (ici S va de 341.8 à 1500 $\rightarrow$ 500 est dans la plage, donc OK) ;
 - chaque **catégorie** utilisée pour une variable qualitative (ici HD = "yes", AE = "low") doit être **présente dans l'échantillon**.
- Une prédiction hors de la plage observée des quantitatives (extrapolation) n'est pas fiable, même si le calcul algébrique reste possible.

Attention : "raisonnable" ne veut jamais dire "positif" ou "de bon sens intuitif" — c'est uniquement une question de savoir si la combinaison de valeurs demandée a un équivalent dans les données observées.

6. Comparer deux modèles emboîtés : le test F partiel

Modèles emboîtés (nested models) : le modèle réduit (mod3) ne contient qu'un sous-ensemble des variables du modèle complet (mod1) — ici $\text{mod3} = \text{CN} \sim \text{S} + \text{HD}$ est emboîté dans $\text{mod1} = \text{CN} \sim \text{S} + \text{HD} + \text{AE}$.

$$H_0 : \beta_{\text{AEaverage}} = \beta_{\text{AEhigh}} = 0$$

```
mod3 <- lm(CN ~ S + HD, data = SUP)
anova(mod3, mod1)
```

Ce que ça calcule concrètement, étape par étape :

- Le test F partiel demande : "est-ce que retirer AE (les 2 muettes ensemble) dégrade significativement l'ajustement du modèle ?"
- Les degrés de liberté du test sont (nombre de variables retirées, ddl résiduels du modèle complet) → ici (2, 145) : 2 muettes retirées, $145 = n - p - 1$ pour mod1 ($150 - 4 - 1$).
- Résultat sur l'exemple : $F = 0.0449$, $p\text{-value} = 0.9561$ → on ne rejette pas H_0 , AE n'apporte rien de significatif une fois S et HD dans le modèle.
- **Un seul terme retiré** (une seule variable ou une seule muette) → le test t (Section 3) et le test F partiel donnent la même conclusion (ils sont mathématiquement équivalents dans ce cas précis). **Plusieurs termes retirés en même temps** (comme ici, les 2 muettes de AE) → seul le test F partiel donne la bonne réponse conjointe ; faire 2 tests t séparés sur AEaverage et AEhigh ne suffit pas.

Attention : le test F partiel ne s'applique qu'à des modèles emboîtés (un modèle est un sous-ensemble strict de l'autre) — jamais à deux modèles qui remplacent une variable par une autre (voir Section 7).

7. Comparer deux modèles non emboîtés : R^2 ajusté

mod1 = $\text{CN} \sim \text{S} + \text{HD} + \text{AE}$ ($R^2 = 0.3996$, R^2 ajusté = 0.383) **vs** **mod2** = $\text{CN} \sim \text{S} + \text{HD} + \text{CA}$ ($R^2 = 0.416$, R^2 ajusté = 0.404).

- mod1 et mod2 ne sont **pas emboîtés** : AE n'est pas un sous-ensemble de CA, ni l'inverse. Un test F partiel ou une comparaison brute du nombre de coefficients (5 vs 4) n'a donc pas de sens ici.
- La seule façon correcte de les comparer est **descriptive**, via le **R^2 ajusté** (qui pénalise le nombre de variables, contrairement au R^2 brut) : mod2 (0.404) > mod1 (0.383) → mod2 explique mieux CN, à complexité comparable.
- Le R^2 brut de mod2 (0.416) > celui de mod1 (0.3996) signifie que la **déviante expliquée** de mod2 est plus grande — mais la déviante totale (basée sur les mêmes CN observés) est identique dans les deux modèles.

Attention : un plus grand nombre de coefficients dans un modèle n'est jamais, en soi, une raison de le préférer — et n'est pas non plus une raison de le rejeter ; seul le R^2 ajusté (modèles non emboîtés) ou le test F partiel (modèles emboîtés) tranchent.

8. Significativité globale du modèle : test F global, R^2 et R^2 ajusté

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \text{ (toutes les pentes nulles à la fois)}$$

Ce que ça calcule concrètement, étape par étape :

- La statistique F du bas de summary () teste si le modèle, dans son ensemble, explique une part significative de la variabilité de Y — c'est le ratio (déviante expliquée / p) divisé par (déviante résiduelle / (n-p-1)).
- Pour mod1 : $F = 24.12$ sur (4, 145) degrés de liberté, $p\text{-value} = 2.604e-15 \rightarrow$ le modèle est globalement très significatif.
- R^2 = proportion de la variabilité de Y expliquée par les variables explicatives. Il **ne peut jamais diminuer** quand on ajoute une variable, même inutile (0.3996 pour mod1, moins de variables aurait donné un R^2 encore plus bas ou égal).
- R^2 ajusté pénalise l'ajout de variables inutiles et **peut diminuer** si la variable ajoutée n'apporte pas assez d'information par rapport au coût en degrés de liberté qu'elle consomme.
- Si $R^2 = 0.6$, alors 60% de la variabilité de Y est expliquée par le modèle et **40% ne l'est pas** — R^2 n'est jamais directement "le pourcentage expliqué par chaque variable individuellement", c'est un chiffre global pour tout le modèle.

Must know :

- R^2 ne peut pas baisser en ajoutant une variable ; R^2 ajusté peut baisser.
- Test F global $\rightarrow H_0$: tous les coefficients de pente nuls en même temps.
- Estimation de la variance des erreurs = (residual standard error)².

9. Passage aux données de panel : effets fixes et test de Hausman

Test de Hausman (Hausman test) : permet de choisir entre un modèle à effets aléatoires (random effects) et un modèle à effets fixes (fixed effects) sur données de panel.

$$H_0 : \text{le modèle à effets aléatoires est cohérent (consistant)}$$

`phtest(modEF, modEA)`

Ce que ça calcule concrètement, étape par étape :

- Sous H_0 , le modèle à effets aléatoires est cohérent **et** plus efficace $\rightarrow$ on le préfère par défaut si on ne rejette pas H_0 .
- On compare la p-value au seuil choisi comme pour n'importe quel test : p-value entre 0.05 et 0.1 (ex. 0.0774) $\rightarrow$ on rejette H_0 au seuil 0.1 (effets fixes choisis) mais pas au seuil 0.05 (effets aléatoires choisis). La conclusion **dépend donc du seuil retenu**, il faut toujours donner les deux si l'énoncé ne précise pas de seuil unique.

Modèle à effets fixes (fixed effects, estimé "within") : chaque individu du panel (ici chaque entreprise) a sa propre ordonnée à l'origine, estimée séparément via ``fixef()``, mais partage la même pente pour les variables explicatives.

```
mod <- plm(sales ~ adv, model = "within", data = S)
fixef(mod)
```

Ce que ça calcule concrètement, étape par étape :

- `fixef(mod)` renvoie un intercept spécifique par individu (ex. 144.048 pour l'entreprise 1, -55.524 pour l'entreprise 2, etc.).
- Le coefficient de la variable explicative (ici `adv` = 25.0203) est **le même pour tous les individus** — seule l'ordonnée à l'origine change d'un individu à l'autre.
- Équation valide pour l'entreprise 1 : $\text{sales-hat} = 144.048 + 25.0203 \cdot \text{adv}$ (on prend l'intercept propre à l'entreprise 1, pas l'intercept "moyen" du modèle sans effets fixes).

Attention : ne jamais utiliser un intercept générique ou une moyenne des `fixef()` pour prédire un individu précis du panel — toujours prendre l'intercept spécifique à cet individu.

10. Fonctions R à connaître par cœur

Liste officielle du cours (20987 A.F.M. 2026-2027) pour le premier in-class test. Utile comme check-list avant l'examen : si une fonction de cette liste apparaît dans une question, il faut savoir dire en une phrase ce qu'elle fait.

- `lm` — estime les modèles linéaires.
- `summary` — résume un objet (coefficients/tests pour un `lm`, distribution pour une variable).
- `confint` — construit les intervalles de confiance des coefficients.
- `predict` — fournit les prédictions et intervalles associés.
- `anova` — donne la décomposition de la déviance et effectue le test F (partiel ou global selon l'appel).
- `data.frame` — définit un jeu de données.
- `str` — montre la structure d'un objet.
- `table` — crée un tableau de fréquences.
- `mean`, `median`, `var`, `cor` — statistiques descriptives (moyenne, médiane, variance, corrélation).
- `plot`, `abline` — graphique, et ajout de droites sur le graphique courant.
- `ls` — liste les objets existants dans l'environnement.
- `library` — charge un package déjà installé.
- `influence.measures`, `rstudent`, `hatvalues` — mesures d'influence, résidus studentisés, leviers (hors périmètre du mock quiz mais dans la liste officielle du 1er test).
- `vif` (package `car`) — facteur d'inflation de la variance (multicolinéarité).
- `plm` (package `plm`) — estime les modèles linéaires sur données de panel.
- `phtest` (package `plm`) — test de Hausman.
- `fixef` (package `plm`) — estime les effets fixes individuels.

11. Erreurs courantes et pièges d'examen

- Introduire k muettes au lieu de $k-1$ pour une variable qualitative à k catégories (colinéarité parfaite avec l'intercept).
- Confondre le coefficient estimé et son erreur standard (`std. error`) en lisant `summary()`.
- Conclure sur la pertinence globale d'une variable qualitative à partir du test t d'une seule de ses muettes, au lieu d'un test F partiel sur le groupe complet.
- Utiliser un test F partiel sur deux modèles non emboîtés (variables différentes) — dans ce cas, seul le R^2 ajusté permet une comparaison.

- Juger une prédiction "raisonnable" ou non sur une intuition de bon sens plutôt que sur la plage réellement observée des variables quantitatives et la présence des catégories dans l'échantillon.
- Oublier qu'un intervalle de confiance à 99% est plus long qu'à 90% (et qu'un intervalle pour une observation individuelle est plus long qu'un intervalle pour la moyenne, au même niveau).
- Penser que le R^2 peut baisser en ajoutant une variable — c'est le R^2 ajusté qui peut baisser, jamais le R^2 brut.
- Sur données de panel, prédire avec un intercept unique/moyen au lieu de l'intercept individuel donné par `fixef()`.
- Oublier que la conclusion du test de Hausman peut changer selon le seuil de significativité retenu (0.05 vs 0.1) quand la p-value tombe entre les deux.

12. À savoir absolument

Must know :

- k catégories → k-1 muettes ; la référence est absorbée dans l'intercept.
- Quantitative → effet marginal par unité, constant quels que soient les niveaux fixés des autres variables (additivité, sans interaction). Muette → écart moyen vs la référence.
- Test t → $H_0 : \beta_j = 0$, une seule variable/muette. Test F partiel → $H_0 : \text{plusieurs } \beta = 0$ en même temps (modèles emboîtés uniquement).
- Modèles non emboîtés → comparaison uniquement via R^2 ajusté.
- Confiance ↑ → intervalle plus long ; intervalle pour une moyenne < intervalle pour une observation individuelle.
- Prédiction raisonnable → valeurs quantitatives dans la plage observée + catégories présentes dans l'échantillon.
- R^2 ne peut pas baisser en ajoutant une variable ; R^2 ajusté peut baisser.
- Panel : test de Hausman → $H_0 = \text{effets aléatoires cohérents}$; `fixef()` donne un intercept par individu, la pente reste commune.

Points de vigilance

Attention : une équation qui garde toutes les catégories d'une variable qualitative en même temps (colinéarité parfaite avec l'intercept) est fausse — respecter la règle k-1.

Attention : un test t sur une seule muette d'une variable à plusieurs catégories ne dit rien sur la pertinence globale de cette variable — il faut un test F partiel sur le groupe complet de muettes.

Attention : le test F partiel ne s'applique qu'à des modèles emboîtés — jamais à deux modèles qui remplacent une variable par une autre.

Attention : "raisonnable" pour une prédiction ne veut jamais dire "de bon sens intuitif" — c'est une question de plage observée (quantitatives) et de catégories présentes (qualitatives).

Attention : ne jamais utiliser un intercept générique pour prédire un individu précis d'un panel à effets fixes — toujours l'intercept spécifique donné par `fixef()`.

Attention : la conclusion du test de Hausman peut changer selon le seuil retenu (0.05 vs 0.1) quand la p-value tombe entre les deux — toujours préciser à quel seuil on conclut.